

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



CAO VIỆT ANH

**NGHIÊN CỨU ỨNG DỤNG HỌC MÁY ĐỀ PHÁT HIỆN
VẬN ĐỘNG BẤT THƯỜNG**

ĐỒ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT
(Theo định hướng ứng dụng)

HÀ NỘI – 2024

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



CAO VIỆT ANH

**NGHIÊN CỨU ỨNG DỤNG HỌC MÁY ĐỂ PHÁT HIỆN
VẬN ĐỘNG BẤT THƯỜNG**

Chuyên ngành: KHOA HỌC MÁY TÍNH

Mã số: 8.48.01.01

ĐỒ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT

(Theo định hướng ứng dụng)

NGƯỜI HƯỚNG DẪN KHOA HỌC: TS. NGUYỄN TẮT THẮNG

HÀ NỘI – 2024

LỜI CAM ĐOAN

Tôi xin cam đoan nội dung trình bày luận văn này là do sự tìm hiểu và nghiên cứu của bản thân. Các kết quả nghiên cứu của các tác giả khác đều được trích dẫn cụ thể.

Luận văn này chưa được bảo vệ tại bất kỳ một hội đồng bảo vệ luận văn thạc sĩ nào trong nước và nước ngoài. Đồng thời, đến nay cũng chưa được công bố trên bất kỳ phương tiện thông tin truyền thông nào.

Tác giả luận văn

Cao Việt Anh

LỜI CẢM ƠN

Lời đầu tiên tác giả xin được bày tỏ lòng biết ơn chân thành tới: TS. Nguyễn Tất Thắng đã tận tình hướng dẫn và định hướng cho tôi trong suốt quá trình làm luận văn.

Tôi xin chân thành cảm ơn Ban lãnh đạo Học viện Công nghệ Bưu chính Viễn thông, Khoa Đào tạo Sau Đại học và quý thầy, cô và các bạn học viên đã tạo điều kiện tốt nhất và giúp đỡ tôi hoàn thành luận văn này.

Tôi xin bày tỏ sự biết ơn tới gia đình, bạn bè và đồng nghiệp đã khích lệ, động viên giúp đỡ cho tôi trong quá trình học tập và thực hiện luận văn.

Cuối cùng, mặc dù trong quá trình thực hiện luận văn này, tôi đã nỗ lực và cố gắng bằng tất cả khả năng của mình, nhưng không thể tránh khỏi những thiếu sót, tôi rất mong nhận được sự thông cảm và góp ý quý báu của quý thầy, cô và các bạn đọc.

Hà nội, ngày tháng năm 2024

Tác giả luận văn

Cao Việt Anh

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
DANH MỤC CÁC TỪ VIẾT TẮT	v
DANH MỤC BẢNG BIỂU	vi
DANH MỤC HÌNH VẼ	vii
MỞ ĐẦU	8
1. Lý do chọn đề tài	8
2. Tổng quan về vấn đề nghiên cứu	8
3. Mục tiêu nghiên cứu của đề tài	10
4. Đối tượng và phạm vi nghiên cứu của đề tài	10
5. Phương pháp nghiên cứu của đề tài	10
6. Bố cục luận văn	14
CHƯƠNG 1 TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG	16
1.1. Bài toán	16
1.1.1. Giới thiệu	16
1.1.2. Tại sao phải phát hiện vận động bất thường	17
1.1.3. Các thách thức trong bài toán phát hiện bất thường cho IoT	18
1.2. Tổng quan về các cảm biến sử dụng để nhận dạng hoạt động ở người	19
1.3. Một số hệ thống phát hiện bất thường đã được thương mại hóa	22
1.4. Tập dữ liệu sử dụng	27
1.5. Kết thúc chương 1	30
CHƯƠNG 2 NGHIÊN CỨU THUẬT TOÁN VÀ CẢM BIẾN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG ỨNG DỤNG MÔ HÌNH TRÍ TUỆ NHÂN TẠO	32
2.1. Giới thiệu chung	32
2.2. Các cảm biến ứng dụng phát hiện vận động	33
2.3. Sơ đồ tổng quát hệ thống phát hiện bất thường	35
2.4. Một số thuật toán ứng dụng trong phát hiện vận động bất thường	37
2.4.1. Thuật toán phát hiện bất thường truyền thống	37
2.4.2. Thuật toán phát hiện VĐBT thông minh sử dụng mô hình học máy	42
2.5. Các tham số đánh giá hiệu năng	45
2.6. Kết luận chương 2	46
CHƯƠNG 3 PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG BẰNG HỌC SÂU	48

3.1. Mô hình đề xuất	48
3.1.1. Dữ liệu thu thập	49
3.1.2. Tiền xử lý dữ liệu	49
3.1.3. Trích chọn đặc trưng	51
3.1.4. Mô hình học sâu	52
3.2. Thực hiện mô hình	54
3.3. Kiểm thử và đánh giá	55
3.3.1. Các tham số đánh giá	55
3.3.2. Đánh giá hiệu năng hệ thống	57
3.4. Kết thúc chương 3	60
KẾT LUẬN	60
DANH MỤC TÀI LIỆU THAM KHẢO	62
TÀI LIỆU THAM KHẢO	63
BẢN CAM ĐOAN	64
PHỤ LỤC	66

(Để làm mục lục tự động thì các đề mục chương phải dùng Styles Heading 1, 2, ... theo đúng mẫu. Nên copy các đề mục chương đã có ra và chèn text mới vào.

Khi cập nhật mục lục thì chọn Right click trên Mục lục, chọn Update Fields là tạo được mục lục tự động)

DANH MỤC CÁC TỪ VIẾT TẮT

STT	Từ viết tắt	Nghĩa Tiếng Anh	Nghĩa Tiếng Việt
1	AI	Artificial Intelligence	Trí tuệ nhân tạo
2	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
3	CPU	Central Processing Unit	Bộ phận xử lý trung tâm
4	CSO	Cuckoo Search Optimization	Tối ưu hóa tìm kiếm Cuckoo
5	DNN	Deep Neural Network	Mạng nơ-ron sâu
6	DoS	Denial of Service	Tấn công từ chối dịch vụ
7	DDoS	Distributed Denial of Service	Tấn công từ chối dịch vụ phân tán
8	DT	Decision Tree	Cây quyết định
10	EMS	Event Management System	Hệ thống quản lý sự kiện
11	FA	Firefly Algorithm	Thuật toán đom đóm
12	FFDNN	Feed Forward Deep Neural	Mạng thần nơ-ron chuyển tiếp
13	FTP	File Transfer Protocol	Giao thức truyền file
14	GA	Genetic Algorithm	Thuật toán di truyền
15	HTTP	Hypertext Transfer Protocol	Giao thức truyền siêu văn bản
16	IDS	Instruction Detection System	Hệ thống phát hiện xâm nhập
17	IoT	Internet of Things	Internet vạn vật
18	IP	Internet Protocol	Giao thức Internet
19	KNN	K - Nearest Neighbor	K-Láng giềng gần nhất
20	LR	Logistic Regression	Hồi quy logistic

DANH MỤC BẢNG BIỂU

Bảng 1.1 Bảng mô tả các Vận động bất thường	11
Bảng 2.1. Một số giá trị xác suất của phân bố GAUSS theo giá trị c.....	38
Bảng 3.1. Chi tiết tập dữ liệu thu thập	49
Bảng 3.2. Chi tiết mô hình học sâu phát hiện VĐBT	54
Bảng 3.3. Ma trận nhầm lẫn	56
Bảng 3.4. Tham số đánh giá cho từng loại dữ liệu	59

(Để làm danh mục bảng biểu tự động thì các tên bảng phải dùng Styles TableCaption theo đúng mẫu. Nên copy các tên bảng đã có ra và chèn text mới vào.

Khi cập nhật danh mục bảng biểu thì chọn Right click trên danh mục, chọn Update Fields là tạo được danh mục bảng biểu tự động)

DANH MỤC HÌNH VẼ

Hình 1.1 Minh họa phát hiện bất thường	16
Hình 1.2 Ứng dụng của phát hiện bất thường	17
Hình 1.3 Cảm biến sử dụng trên các bộ phận của cơ thể người	19
Hình 1.4 SureSafeGo 2	23
Hình 1.5 Thiết bị Sentry	24
Hình 1.6 Hệ thống phát hiện ngã GreatCall Lively	24
Hình 1.7 Hệ thống phát hiện ngã Buddi	25
Hình 1.8 Hệ thống phát hiện ngã Bay Alarm Medical	26
Hình 2.1. Học máy trong bài toán phát hiện bất thường	32
Hình 2.2 Cảm biến gia tốc	33
Hình 2.3. Con quay hồi chuyển (trái), cảm biến con quay hồi chuyển LPY03(phải)	34
Hình 2.4. Mô tả hệ thống phát hiện bất thường	36
Hình 2.5. Hàm mật độ xác suất (PDF) trong phân bố GAUSS	38
Hình 3.1 Mô tả tổng quan về hệ thống phát hiện VĐBT	48
Hình 3.2 Tiền xử lý dữ liệu thu thập	50
Hình 3.3 Quá trình huấn luyện mô hình	52
Hình 3.4. Trực quan hóa mô hình học sâu phát hiện VĐBT	53
Hình 3.4. Độ chính xác theo giá trị Epoch trong quá trình huấn luyện và xác thực	58
Hình 3.5 Giá trị mất mát theo giá trị Epoch trong quá trình huấn luyện và xác thực	58
Hình 3.5. Ma trận nhầm lẫn của mô hình trong quá trình kiểm thử	59

(Để làm danh mục hình vẽ tự động thì các tên hình vẽ phải dùng Styles FigureCaption theo đúng mẫu. Nên copy các tên hình đã có ra và chèn text mới vào.

Khi cập nhật danh mục hình vẽ thì chọn Right click trên danh mục, chọn Update Fields là tạo được danh mục hình vẽ tự động)

MỞ ĐẦU

1. Lý do chọn đề tài

Các vận động bất thường, đặc biệt là ngã, gây nguy hiểm và ảnh hưởng tiêu cực đến sức khỏe, đặc biệt ở người cao tuổi. Việc tự động phát hiện các vận động này để cảnh báo và hỗ trợ kịp thời đã thu hút sự quan tâm của nhiều nhà nghiên cứu. Sự phát triển của công nghệ tính toán di động và cảm biến thông minh tích hợp trong các thiết bị như điện thoại, đồng hồ thông minh, và kính đã mở ra cơ hội phân tích tín hiệu vận động hàng ngày để cung cấp thông tin về sức khỏe. Hệ thống phát hiện ngã là một công cụ hỗ trợ với mục đích chính là tạo ra cảnh báo nếu xảy ra ngã. Những hệ thống này cho thấy hứa hẹn lớn trong việc giảm bớt một số tác động tiêu cực của ngã. Các thiết bị phát hiện ngã có ảnh hưởng đáng kể đến việc cung cấp sự trợ giúp ngay lập tức sau khi xảy ra ngã cũng như giảm nỗi sợ hãi khi ngã. Ngã và sự sợ hãi về việc ngã có mối liên hệ: sự sợ hãi khi bị ngã có thể làm tăng khả năng một người sẽ bị ngã.

Nhiều nghiên cứu đã được thực hiện để tạo ra các chiến lược và phương pháp nhằm cải thiện khả năng chức năng của người cao tuổi và người ốm. Một số hệ thống sử dụng camera, cảm biến và công nghệ máy tính. Những hệ thống như vậy cho người cao tuổi có thể vừa cải thiện khả năng sống độc lập bằng cách nâng cao cảm giác an toàn trong môi trường hỗ trợ, vừa giảm bớt khối lượng công việc chăm sóc bằng cách giảm nhu cầu sử dụng y tá hoặc nhân viên hỗ trợ khác. Tuy nhiên, nhiều hệ thống phát hiện vận động bất thường hiện có chi phí cao và chưa phù hợp với điều kiện tại Việt Nam. Do đó, luận án này tập trung nghiên cứu các phương pháp học máy để phát hiện vận động bất thường, đặc biệt là ngã, sử dụng cảm biến đeo, thực hiện theo thời gian thực nhằm đáp ứng nhu cầu trong nước.

Với lý do trên, học viên đã quyết định lựa chọn đề tài **“Nghiên cứu ứng dụng học máy để phát hiện vận động bất thường”** để thực hiện đề án tốt nghiệp thạc sĩ.

2. Tổng quan về vấn đề nghiên cứu

Cùng với sự phát triển mạnh mẽ của cuộc cách mạng công nghiệp 4.0, AI ngày càng được ứng dụng phổ biến và rộng rãi trong mọi lĩnh vực của cuộc sống. Đặc trưng của công nghệ AI là năng lực “tự học” của máy tính, do đó có thể tự phân đoán, phân tích trước các dữ liệu mới mà không cần sự hỗ trợ của con người, đồng thời có khả năng xử lý dữ liệu với số lượng rất lớn và tốc độ cao. Với xu thế phát triển công nghệ và ứng dụng trong đời sống xã hội đang thay đổi không ngừng, thì công nghệ AI đang là ứng dụng tiềm năng nhất và là công nghệ chủ chốt trong tương lai.

Nghiên cứu ứng dụng học máy tại biên để phát hiện hành vi vận động bất thường (VĐBT) là một lĩnh vực đầy tiềm năng, đặc biệt quan trọng trong việc chăm sóc sức khỏe và hỗ trợ người cao tuổi. Các hành vi vận động bất thường, như ngã, không chỉ gây nguy hiểm mà còn có tác động tiêu cực đến sức khỏe con người. Việc phát hiện sớm những hành vi này để đưa ra cảnh báo kịp thời có thể giảm thiểu rủi ro và nâng cao chất lượng cuộc sống. Với sự phát triển mạnh mẽ của công nghệ tính toán di động và tính toán tỏa khắp, các cảm biến thông minh đã được tích hợp vào nhiều thiết bị như điện thoại thông minh, đồng hồ thông minh, và các thiết bị đeo khác. Những cảm biến này thu thập dữ liệu vận động của người dùng hàng ngày và cung cấp thông tin hữu ích về sức khỏe thông qua các ứng dụng phân tích. Các nghiên cứu trước đây đã phát triển nhiều hệ thống phát hiện VĐBT, tập trung chủ yếu vào phát hiện ngã.

Hiện nay cũng đã có một số thiết bị đeo mà điển hình như đồng hồ Apple Watch của Apple có khả năng phát hiện ngã, tuy nhiên giá thành thiết bị còn tương đối cao với người dùng ở Việt Nam, hơn nữa người dùng cần phải sử dụng các thiết bị khác trong “hệ sinh thái” của Apple như iPhone, iPad để đồng bộ hoá dữ liệu. Tuy nhiên, các hệ thống này thường có chi phí cao và chưa được kiểm chứng về tính hiệu quả khi áp dụng tại Việt Nam. Hơn nữa, các phương pháp hiện tại chưa khai thác hết tiềm năng của các cảm biến đeo phổ biến và công nghệ học máy tiên tiến. Đặc biệt, sự xuất hiện của TinyML (Tiny Machine Learning) - công nghệ học máy trên các thiết bị vi mô với tài nguyên hạn chế - đã mở ra những cơ hội mới cho việc phát

hiện VĐBT. TinyML cho phép triển khai các mô hình học máy ngay tại biên của mạng, trên các thiết bị có bộ nhớ và khả năng xử lý hạn chế như cảm biến và thiết bị đeo thông minh. Điều này giúp giảm độ trễ, tiết kiệm năng lượng, và bảo vệ quyền riêng tư của người dùng bằng cách xử lý dữ liệu tại nguồn. Do đó, luận án tập trung vào việc ứng dụng học máy tại biên và TinyML để phát hiện VĐBT theo thời gian thực, sử dụng các cảm biến đeo phổ biến.

3. Mục tiêu nghiên cứu của đề tài

- Tập trung vào phát hiện ngã bằng cảm biến và trích chọn đặc trưng từ cảm biến
- Đề xuất mô hình học sâu hiệu quả từ dữ liệu cảm biến cho bài toán nhận dạng hoạt động và phát hiện vận động bất thường ngay tại thiết bị đeo.
- Đề xuất được phương pháp phát hiện VĐBT hiệu quả cả trong trường hợp không đủ dữ liệu cho huấn luyện.

4. Đối tượng và phạm vi nghiên cứu của đề tài

Đối tượng nghiên cứu của luận án bao gồm các hành vi vận động bất thường, đặc biệt là hành vi ngã, và các cảm biến đeo phổ biến. Nghiên cứu sẽ tập trung vào các phương pháp học máy và học sâu tiên tiến, bao gồm cả TinyML, để phát hiện hành vi vận động bất thường. Phạm vi nghiên cứu sẽ bao gồm việc trích chọn đặc trưng thủ công và tự động từ dữ liệu thu thập từ các cảm biến đeo, thực nghiệm trên các tập dữ liệu tự thu thập và các tập dữ liệu đã công bố, và phát triển cũng như đánh giá các mô hình học máy và học sâu nhằm phát hiện VĐBT theo thời gian thực trên các thiết bị có tài nguyên hạn chế. Mục tiêu cuối cùng là nâng cao độ chính xác và hiệu quả của hệ thống phát hiện VĐBT trong điều kiện thực tế, đặc biệt là đối với người cao tuổi tại Việt Nam.

5. Phương pháp nghiên cứu của đề tài

Đề án áp dụng phương pháp thu thập và phân tích các nghiên cứu liên quan trước đó nhằm xác định những ưu điểm và hạn chế, từ đó phát triển một hệ thống và bộ

dữ liệu để đánh giá hiệu suất của mô hình. Quá trình bao gồm các bước: đầu tiên, thu thập dữ liệu từ các cảm biến như gia tốc kế và con quay hồi chuyển để ghi nhận các vận động bình thường và bất thường. Tiếp theo, dữ liệu được tiền xử lý thông qua các bước làm sạch, chuẩn hóa và trích xuất các đặc trưng quan trọng như tốc độ và quỹ đạo chuyển động. Sau đó, sử dụng thuật toán học máy CNN để xây dựng mô hình phát hiện vận động bất thường. Để tối ưu hóa mô hình cho các thiết bị nhúng, phương pháp lượng tử hóa mô hình được áp dụng, giúp giảm kích thước mô hình và cải thiện hiệu quả tính toán mà không làm giảm đáng kể độ chính xác. Sau khi hoàn tất quá trình huấn luyện, mô hình được kiểm tra và đánh giá thông qua các chỉ số như độ chính xác (Accuracy), độ nhạy (Recall) và F1-score. Cuối cùng, mô hình được triển khai trên các thiết bị nhúng tại biên trên vi điều khiển để kiểm tra hiệu suất phát hiện bất thường trong môi trường thực tế. Việc triển khai trên các thiết bị nhúng giúp giảm thiểu độ trễ và tiết kiệm băng thông, đảm bảo mô hình hoạt động hiệu quả với tài nguyên tính toán hạn chế, đồng thời cung cấp khả năng phát hiện vận động bất thường ngay tại chỗ, không cần phụ thuộc vào kết nối với các máy chủ đám mây.

- **Các vận động và vận động bất thường:**

Vận động bất thường được hiểu là những hành động hoặc biểu hiện chuyển động không phù hợp hoặc khác biệt so với các hoạt động bình thường của con người, thường phản ánh tình trạng sức khỏe không ổn định hoặc tác động từ môi trường xung quanh. Các vận động này có thể bao gồm những hành động như té ngã, lão đảo, hoặc gặp khó khăn trong việc di chuyển, và thường là dấu hiệu của các vấn đề nghiêm trọng như mất thăng bằng, chấn thương, hoặc suy giảm sức khỏe. Việc phát hiện sớm những vận động bất thường rất quan trọng trong việc giám sát an toàn, đặc biệt là ở người cao tuổi, giúp cung cấp cảnh báo kịp thời và hỗ trợ cần thiết, từ đó giảm thiểu nguy cơ chấn thương nghiêm trọng và nâng cao chất lượng cuộc sống. Dưới đây là bảng tổng hợp các vận động bình thường và bất thường dự kiến trong tập dữ liệu tự thu thập.


Bảng 1.1 Bảng mô tả các Vận động bất thường

STT	Tên hoạt động và VĐBT	Mô tả
1	Đứng im	Là hành động này diễn ra khi một người giữ nguyên tư thế đứng mà không di chuyển trong một khoảng thời gian nhất định.
2	Vận động ngồi xuống	Hành động này diễn ra khi một người chuyển từ tư thế đứng sang tư thế ngồi.
3	Vận động đứng lên	Hành động này là quá trình chuyển đổi từ tư thế ngồi hoặc nằm sang tư thế đứng.
4	Vận động đi bộ	Hành động đi bộ là hoạt động cơ bản và tự nhiên của con người, thể hiện sự di chuyển từ vị trí này đến vị trí khác
5	Té ngã	Là một trong những vận động bất thường phổ biến nhất

- **Phần cứng:**

Đề án này sử dụng vi điều khiển ESP32-S3 làm bộ xử lý trung tâm, một lựa chọn lý tưởng nhờ vào hiệu năng mạnh mẽ và giá thành hợp lý (khoảng 200 nghìn VNĐ). ESP32-S3, thuộc dòng ESP32 của Espressif, được trang bị bộ vi xử lý dual-core Xtensa LX7 với tốc độ lên đến 240 MHz, cùng 512 KB SRAM và hỗ trợ bộ nhớ flash ngoài lên đến 16MB, giúp xử lý các tác vụ phức tạp và lưu trữ dữ liệu lớn. Đặc biệt, ESP32-S3 tích hợp các thành phần tăng tốc AI và vector instructions, tối ưu hiệu năng cho các ứng dụng machine learning và tinyML (Tiny Machine Learning), nơi yêu cầu sự kết hợp giữa hiệu suất cao và tiết kiệm năng lượng. Khả năng kết nối Wi-Fi và Bluetooth 5.0 (BLE) giúp ESP32-S3 dễ dàng giao tiếp trong các hệ thống IoT. Vi điều khiển này được kết nối với cảm biến MPU6050, có giá khoảng 50 nghìn VNĐ, bao gồm gia tốc kế 3 trục và con quay hồi chuyển 3 trục, giúp theo dõi chuyển động với độ chính xác cao. MPU6050 sử dụng giao tiếp I2C để kết nối với ESP32-S3, với tốc độ giao tiếp tối đa lên đến 400 kbit/s. Cảm biến này cũng tích hợp bộ xử lý chuyển động số (DMP), cho phép thực hiện các thuật toán phức tạp như bộ lọc Kalman trực tiếp trên cảm biến, giảm tải cho vi điều khiển.

- **Kế hoạch triển khai:**



Trong đề án này, học viên đề xuất sáu bước chính để triển khai bài toán phát hiện vận động bất thường, như được mô tả trong sơ đồ tổng quát. Đầu tiên, học viên xây dựng phần cứng đáp ứng các tiêu chí nhỏ gọn, giá thành rẻ, và có thể dễ dàng đeo trên người, thuận tiện cho việc thu thập dữ liệu và đánh giá thực tế. Tiếp theo, học viên tiến hành thu thập và xây dựng tập dữ liệu, bao gồm các trạng thái vận động như ngã, đứng yên, ngồi xuống, đứng lên, đi bộ... Dữ liệu thô thu được từ cảm biến sau đó sẽ trải qua quá trình tiền xử lý, bao gồm lọc và loại bỏ nhiễu, để chuẩn bị cho các bước tiếp theo. Sau khi tiền xử lý, dữ liệu được đưa vào quá trình huấn luyện mô hình sử dụng nền tảng Edge Impulse, giúp trích xuất đặc trưng, xây dựng và triển khai các mô hình học máy cho thiết bị tại biên (Edge). Tiếp theo, mô hình được lượng tử hóa nhằm giảm kích thước, giúp tối ưu hóa và làm cho mô hình phù hợp với khả năng xử lý của vi điều khiển. Cuối cùng, mô hình được triển khai trên thiết bị để đánh giá độ chính xác và chứng minh tính khả thi của bài toán.

- **Thuật toán:**

Trong đề án có sử dụng thuật toán Convolutional Neural Network (CNN) được ứng dụng vào việc phát hiện bất thường ngã trên dữ liệu cảm biến gia tốc. Đầu tiên, dữ liệu từ cảm biến gia tốc được thu thập và chuyển đổi thành dạng hình ảnh hoặc chuỗi thời gian, giúp mô hình CNN có thể nhận diện các đặc trưng quan trọng. Các lớp chập (convolutional layers) trong mạng sẽ tự động học các đặc trưng từ dữ liệu đầu vào. Sau khi trải qua các lớp gộp (pooling layers) để giảm thiểu kích thước và tính toán, dữ liệu được đưa qua các lớp kết nối đầy đủ (fully connected layers) để thực hiện phân loại. Mô hình CNN được huấn luyện bằng cách sử dụng một tập dữ

liệu bao gồm các ví dụ của vận động bình thường và bất thường (như té ngã), với mục tiêu tối ưu hóa các tham số mạng để tối đa hóa độ chính xác trong việc phát hiện các tình huống bất thường. Một trong những ưu điểm lớn của CNN là khả năng tự động trích xuất các đặc trưng quan trọng từ dữ liệu mà không cần phải thiết lập các đặc trưng thủ công, điều này đặc biệt có lợi cho các thiết bị nhúng với tài nguyên hạn chế, như ESP32. Điều này cho phép mô hình hoạt động hiệu quả ngay cả trong môi trường có hạn chế về bộ nhớ và năng lượng.

6. Bố cục luận văn

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG

Giới thiệu chương:

Nội dung:

- Giới thiệu bài toán
- Tổng quan về các phương pháp phát hiện vận động bất thường
- Tổng quan về các cảm biến sử dụng để nhận dạng hoạt động ở người

Kết luận chương 1:

CHƯƠNG 2: NGHIÊN CỨU THUẬT TOÁN VÀ CẢM BIẾN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG ỨNG DỤNG MÔ HÌNH HỌC MÁY

Giới thiệu chương:

Nội dung:

- Một số thuật toán trong phát hiện bất thường
- Phân tích các ưu điểm và hạn chế của các thuật toán.
- Các cảm biến sử dụng trong bài toán
- Các tập dữ liệu sử dụng trong mô hình hệ thống phát hiện bất thường.

Kết luận chương 2:

CHƯƠNG 3: ÁP DỤNG HỌC MÁY VÀO PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG

Giới thiệu chương:

Nội dung:

- Đề xuất xây dựng mô hình hệ thống phát hiện vận động bất thường.
- Thiết lập thử nghiệm hệ thống phát hiện vận động bất thường dựa trên thuật toán.
- Đánh giá kết quả thử nghiệm.

Kết luận chương 3:

CHƯƠNG 1 TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG

1.1. Bài toán

1.1.1. Giới thiệu

Vận động bất thường là những vận động không có tính chủ ý, khoảng thời gian của hành động ngắn, và thường để lại hậu quả không mong muốn cho con người như: chấn thương, va đập... Vận động bất thường điển hình như ngã, có thể diễn ra trong quá trình con người đang thực hiện các hoạt động thường ngày, không có tính thường xuyên và không được dự báo trước. Bài toán phát hiện vận động bất thường hiện đang thu hút được sự quan tâm của các nhà nghiên cứu vì nó có nhiều ứng dụng thực tế như trợ giúp chăm sóc người cao tuổi, cảnh báo sớm nhằm giảm tối đa mức độ nghiêm trọng của hành vi...



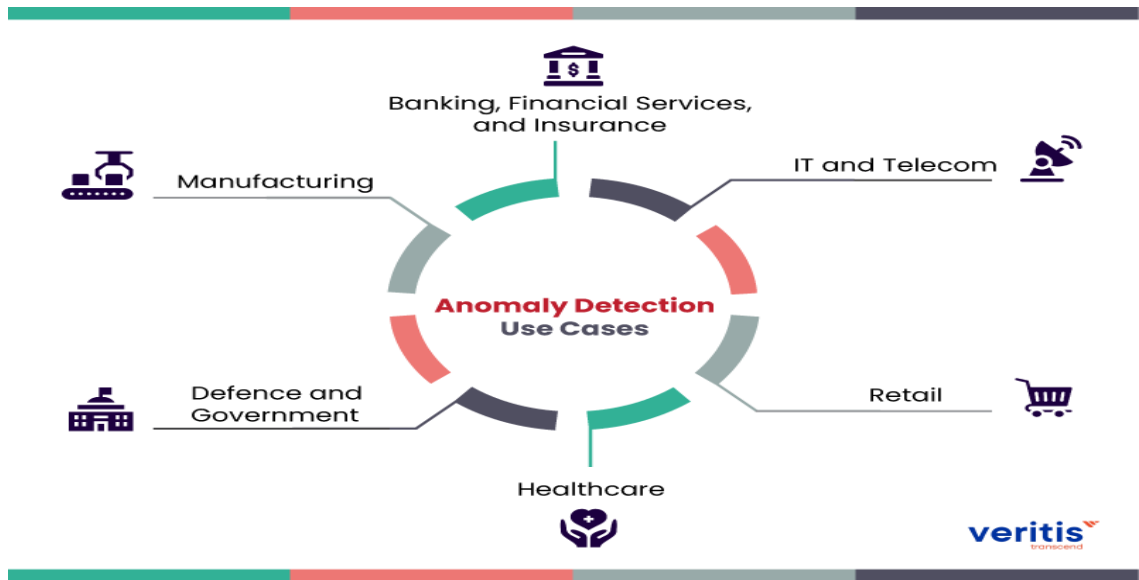
Hình 1.1 Minh họa phát hiện bất thường

Tuy nhiên, hiện nay những hệ thống phát hiện vận động bất thường có thể gặp khó khăn trong quá trình huấn luyện do dữ liệu về hành động, hành vi khá khan hiếm. Sự hạn chế của dữ liệu huấn luyện dẫn đến hiệu suất của các hệ thống phát hiện vận động bất thường không cao, kết quả đưa ra có thể không chính xác.

Nếu xét theo khía cạnh cảm biến sử dụng, các nghiên cứu phát hiện vận động thường tiếp cận theo các phương pháp như: Phân tích hình ảnh hoạt động ở người bằng camera hay còn gọi thị giác máy, phân tích dữ liệu cảm biến từ các bộ cảm biến được tích hợp vào môi trường hoặc vật dụng và phân tích dữ liệu cảm biến từ các bộ cảm biến được đeo trên người (cảm biến đeo). So sánh với cách tiếp cận thị giác máy, nếu sử dụng các cảm biến đeo có thể thực hiện theo dõi hành vi người dùng liên tục trong một thời gian dài, các cảm biến đeo cũng không gây ra cảm giác mất quyền riêng tư cho người dùng, nó ít chịu tác động của môi trường như ánh sáng, vật cản... Thế nhưng, việc sử dụng các cảm biến đeo cũng đặt ra các thách thức như: Dữ liệu thu thập từ nhiều cảm biến là không đồng nhất, khả năng lưu trữ, xử lý dữ liệu và năng lượng để cảm biến có thể hoạt động trong một thời gian dài còn hạn chế.

Nếu xét theo khía cạnh xử lý dữ liệu, các nghiên cứu về phát hiện vận động bất thường tiếp cận theo hai hướng chính: Sử dụng các phương pháp học máy; sử dụng các phương pháp học máy kết hợp khai phá dữ liệu để phát hiện các ngoại lệ.

1.1.2. Tại sao phải phát hiện vận động bất thường



Hình 1.2 Ứng dụng của phát hiện bất thường

Bài toán phát hiện vận động bất thường có nhiều ứng dụng trong các lĩnh vực chăm sóc sức khỏe, an ninh – an toàn và bảo mật. Trong lĩnh vực chăm sóc sức khỏe,

vận động bất thường gây ra những hậu quả đáng tiếc cho con người (điển hình là ngã) hay có thể là những biểu hiện ban đầu ở người có bệnh lý về vận động. Do vậy, rất cần có một hệ thống phát hiện vận động bất thường giúp theo dõi, hỗ trợ người bệnh, người cao tuổi, hơn nữa có thể phát hiện và cảnh báo sớm nhằm tối thiểu hóa hậu quả. Đối với lĩnh vực an ninh – an toàn và bảo mật, giả sử cần theo dõi hoạt động của tất cả mọi người trong một khu vực cần bảo vệ đặc biệt, người ta sử dụng các cảm biến (có thể gắn trên các cá thể định danh). Các cảm biến giúp theo dõi hoạt động, nếu có hành động hoặc hành vi được coi là bất thường, hệ thống sẽ cảnh báo cho bộ phận quản lý về rủi ro an ninh – an toàn.

Đã có nhiều nghiên cứu thành công trong việc nhận dạng hoạt động hằng ngày của con người như đi, đứng, ngồi, chạy, nhảy hay tập luyện thể thao v.v. Nhưng ở đây, vận động bất thường có tính chất là vận động không thường xuyên xảy ra, thời gian diễn ra nhanh, không có tính chủ động, là vận động phức tạp, khó mô tả chính xác, ít lặp lại, những điều này dẫn đến việc thu thập dữ liệu huấn luyện cho các hệ thống phát hiện gặp nhiều khó khăn, làm cho hiệu suất phát hiện VDBT của các hệ thống thường không cao khi triển khai trong thực tế. Đây cũng là thách thức lớn cần giải quyết đối với bài toán phát hiện vận động bất thường.


1.1.3. Các thách thức trong bài toán phát hiện bất thường cho IoT

Trong những năm gần đây, ứng dụng các kỹ thuật học máy (Machine Learning) phát hiện bất thường để bảo hệ, cảnh báo sớm cho các hệ thống IoT đã có những bước phát triển mạnh mẽ. Các mô hình học máy được huấn luyện trên tập dữ liệu bình thường và bất thường, sau đó được sử dụng để xây dựng một mô hình có khả năng phân loại và phát hiện các điểm bất thường trong dữ liệu. Tuy nhiên, việc phát triển các phương pháp phát hiện bất thường trên các hệ thống IoT đầy thách thức do một số yếu tố như:

- Dữ liệu không chuẩn: Dữ liệu từ các thiết bị IoT có thể không đồng nhất về cấu trúc và định dạng, điều này làm cho việc phát hiện bất thường trở nên phức tạp. Sự không thống nhất này có thể làm giảm hiệu suất của các thuật toán phát hiện bất thường.

- Sự thay đổi môi trường: Môi trường hoạt động của các thiết bị IoT thường thay đổi đột ngột, ví dụ như sự biến đổi thời tiết, nhiễu mạng, hoặc thậm chí là sự can thiệp từ con người. Những thay đổi này có thể tạo ra các bất thường không mong muốn trong dữ liệu.
- Sự thiếu hụt dữ liệu: Trong một số trường hợp, dữ liệu từ các thiết bị IoT có thể bị mất hoặc không đủ để đào tạo mô hình phát hiện bất thường. Sự thiếu hụt dữ liệu có thể làm giảm độ chính xác của quá trình phát hiện bất thường.
- Tính toán và tài nguyên hạn chế: Trong một số trường hợp, các thiết bị IoT có tính toán và tài nguyên hạn chế, làm cho việc triển khai các thuật toán phức tạp để phát hiện bất thường trở nên khó khăn. Đòi hỏi sự tinh giản và tối ưu trong các giải pháp phát hiện bất thường.
- Tính đa dạng của dữ liệu IoT: Dữ liệu từ các loại thiết bị IoT khác nhau có thể đa dạng, bao gồm dữ liệu từ cảm biến, camera, bộ cảm biến và hệ thống điều khiển. Việc kết hợp và phân tích dữ liệu đa dạng này đòi hỏi các kỹ thuật phát hiện bất thường phức tạp và linh hoạt.
- Thách thức về cập nhật và duy trì: Các thiết bị IoT thường được triển khai trong môi trường phức tạp và khó tiếp cận, làm cho việc cập nhật và duy trì các phần mềm và firmware trở nên khó khăn. Sự thiếu cập nhật có thể tạo ra các lỗ hổng bảo mật và làm giảm khả năng phát hiện bất thường.

1.2. Tổng quan về các cảm biến sử dụng để nhận dạng hoạt động ở người



Hình 1.3 Cảm biến sử dụng trên các bộ phận của cơ thể người

Trong lĩnh vực nhận dạng hoạt động ở người nói chung và phát hiện VĐBT nói riêng, cảm biến có vai trò như một trình điều khiển rất quan trọng, cảm biến giúp theo dõi chuyển động, môi trường và các thông số khác từ xa, dữ liệu từ cảm biến được truyền qua các giao thức thông dụng, đặc biệt là các giao thức không dây như Wifi, Bluetooth...

Các cảm biến đang ngày càng phổ biến trên các thiết bị và vật dụng mà con người sử dụng hằng ngày, những cải tiến vượt bậc trong công nghệ chế tạo cảm biến đã cho ra đời những cảm biến có kích thước nhỏ, tiêu thụ ít năng lượng, có thể hoạt động bền bỉ và ít chịu ảnh hưởng bởi môi trường. Quan trọng hơn, các cảm biến có thể giao tiếp không gây vướng víu với các thiết bị khác và có giá thành ngày một rẻ nên chúng đã trở nên thông dụng, các cảm biến thường được tích hợp vào các thiết bị thông minh để thu thập thông tin, tính toán, hay tương tác liên tục khi di chuyển. Các cảm biến hiện nay khá phù hợp để mang theo người (cảm biến đeo), có thể sử dụng trong một thời gian dài mà ít gây phiền toái cho người dùng, sử dụng các cảm biến đeo sẽ không còn bị giới hạn trong những căn phòng với các thiết bị được thiết lập sẵn, chính điều này góp phần phát triển các ứng dụng trong nhận dạng hoạt động và chăm sóc sức khỏe.

Nổi bật trong số các cảm biến đeo được sử dụng để nhận dạng hoạt động ở người nói chung và phát hiện vận động bất thường nói riêng là các cảm biến quán tính bao gồm gia tốc kế (cảm biến gia tốc), con quay hồi chuyển và từ kế (cảm biến từ trường). Các cảm biến quán tính có ưu điểm nhỏ gọn, dễ mang theo, dễ thương mại hóa, do đó nó thường được tích hợp trên đồng hồ, điện thoại, nhẫn, tai nghe, kính mắt, mặt dây chuyền..., là những vật dụng thường được con người mang theo trong một thời gian dài. Tuy nhiên chúng cũng có nhược điểm là năng lượng tiêu thụ thường ảnh hưởng đến hiệu suất hoạt động của cảm biến trong trường hợp phải hoạt động liên tục và độ nhạy cảm với chuyển động cơ thể có thể dẫn đến nhận dạng sai hoạt động.

Các cảm biến quán tính được thiết lập trên những vị trí khác nhau của cơ thể người, thường là cổ tay (có trong đồng hồ thông minh), cổ chân (có trong giày thông minh) và thắt lưng (có trong điện thoại thông minh). Cảm biến gia tốc thu nhận sự

thay đổi vị trí của cơ thể và có thể được kết hợp với con quay hồi chuyển để đo các chuyển động quay có sự phục hồi tư thế. Khi kết hợp cả hai cảm biến này có thể xác định chính xác một số hoạt động của con người như đi lên/xuống cầu thang, ngồi, đi bộ, chạy, nhảy. Các nhận dạng này có ý nghĩa quan trọng để xây dựng các ứng dụng liên quan đến phục hồi chức năng, dáng đi, bệnh lý khớp, bệnh Parkinson và phát hiện ngã. Ngoài ra, sự kết hợp giữa cảm biến gia tốc với cảm biến áp suất cũng có thể phát hiện chính xác ngã và hoạt động đi cầu thang.

Các cảm biến hình ảnh được sử dụng để ghi lại hoạt động, cảm xúc hoặc các ngữ cảnh khác nhau của con người. Tiêu biểu cho các loại cảm biến này có SenseCam, Sony Xperia eye, Microsoft Camera Kinect... Dữ liệu về các hoạt động hằng ngày của người dùng trong đó có ngã được các cảm biến này ghi lại, cùng với các dữ liệu về vị trí và được sử dụng cho các ứng dụng chăm sóc người cao tuổi tại nhà. Tuy nhiên so với các công nghệ cảm biến khác, việc sử dụng các công nghệ cảm biến hình ảnh trong chăm sóc sức khỏe đặt ra các thách thức lớn về bảo mật, quyền riêng tư và khả năng lưu trữ dữ liệu.

Trong công nghệ cảm biến còn bao gồm các cảm biến môi trường như cảm biến nhiệt độ, độ ẩm, cảm biến chấn động, cảm biến khói.... Những cảm biến này được sử dụng nhiều trong các nghiên cứu về nhà thông minh, bệnh viện thông minh v.v. Ngoài ra một vài nghiên cứu còn sử dụng cảm biến sợi quang để phát hiện tư thế, điện trở đo áp lực để phát hiện các cơn co thắt cơ bắp. Tuy nhiên đối với bài toán phát hiện VDBT, các cảm biến này ít được sử dụng.

Một loại cảm biến khác đã xuất hiện trên một số sản phẩm đeo thương mại và các ứng dụng thu thập dữ liệu sức khỏe là cảm biến lai. Moves là một ứng dụng sử dụng dữ liệu gia tốc và GPS cho phép theo dõi việc di chuyển của người dùng bao gồm khoảng cách, tốc độ và vị trí. Các thiết bị đeo thương mại như Withings, Fibit Flex sử dụng những cảm biến này để đo số bước đi, khoảng cách di chuyển và lượng calorie tiêu thụ của người dùng, những dữ liệu này thường được đồng bộ với điện thoại qua bluetooth và có thể được chia sẻ với các ứng dụng có liên quan. Hiện nay cũng đã có một số thiết bị đeo mà điển hình như đồng hồ Apple Watch của Apple có

khả năng phát hiện ngã, tuy nhiên giá thành thiết bị còn tương đối cao với người dùng ở Việt Nam, hơn nữa người dùng cần phải sử dụng các thiết bị khác trong “hệ sinh thái” của Apple như iPhone, iPad để đồng bộ hoá dữ liệu.

Tuy công nghệ cảm biến đã đạt được nhiều tiến bộ đáng kể, nhưng vẫn có những hạn chế nhất định. Kích thước của cảm biến tuy nhỏ nhưng khi được thiết lập trên cơ thể vẫn gây ra sự bất tiện trong việc theo dõi lâu dài. Các thiết bị đeo thương mại tuy nhiều nhưng đa số chúng vẫn chỉ được sử dụng cho các hoạt động thể dục thể thao, các sản phẩm này đơn giản là cung cấp các phép đo đã được xử lý như số bước đi, khoảng cách, lượng calorie tiêu thụ v.v., chưa có nhiều sản phẩm phát hiện VDBT, đặc biệt ở Việt Nam. Một số dữ liệu thô thu thập từ cảm biến trong các thiết bị như điện thoại, đồng hồ có nhiều nhiễu do sự đa dạng của hoạt động, vị trí để thiết bị trên người, vấn đề về pin và các tác động của môi trường tự nhiên. Vì vậy, việc xác thực các dữ liệu này vẫn còn là vấn đề mang nhiều thách thức.

1.3. Một số hệ thống phát hiện bất thường đã được thương mại hóa

Hiện nay, đã có một số hệ thống phát hiện VDBT, chủ yếu là phát hiện ngã được thương mại hoá ở nước ngoài, tuy nhiên khi sử dụng các hệ thống này, người dùng ngoài việc phải đầu tư mua thiết bị ban đầu thì cần phải trả thêm chi phí duy trì dịch vụ hằng tháng, cụ thể như một số hệ thống phát hiện vận động ngã như:



Hệ thống phát hiện ngã có tên SureSafeGO 2 sử dụng SIM chuyển vùng được cài đặt sẵn và tích hợp GPS với bản đồ Google Map để xác định vị trí của người bị ngã, thiết bị có khả năng đàm thoại hai chiều. Khi bị ngã người sử dụng sẽ nhấn một nút trên thiết bị để gọi Trung tâm ứng phó SureSafe nhờ hỗ trợ. Thiết bị có giá 149,95 bảng Anh (khoảng 4,5

Hình 1.4 SureSafeGo 2

triệu VNĐ) và phí duy trì dịch vụ là 18,99 bảng mỗi tháng (khoảng 580 nghìn VNĐ/tháng).



Hệ thống phát hiện ngã có tên Sentry được phát triển bởi công ty BlueStar Senior Tech bao gồm một bộ được kết nối với điện thoại cố định cho phép tự động thực hiện cuộc gọi khi có cảnh báo và một thiết bị có kích thước nhỏ (như mặt dây chuyền) có thể truyền tín hiệu cảnh báo từ người đeo đến thiết bị kết nối với điện thoại cố định trong phạm vi khoảng 180m. Hệ thống phù hợp cho việc theo dõi và phát hiện ngã tại nhà có giá thuê bao hàng tháng là 35,95 USD/ tháng (khoảng 940 nghìn VNĐ/ tháng).

Hình 1.5 Thiết bị Sentry

Hệ thống phát hiện ngã có tên GreatCall Lively bao gồm một thiết bị có kiểu dáng như mặt dây chuyền đeo ở cổ, giúp đưa ra cảnh báo khi người sử dụng bị ngã. Khi phát hiện ra ngã, GreatCall Lively sẽ kết nối với các trạm thu nhận để gửi cảnh báo đến các thành viên trong gia đình ngay lập tức. Điểm khác biệt với các thiết bị khác



là nó yêu cầu người dùng phải sử dụng điện thoại di động có cài đặt ứng dụng GreatCall và kết nối với di động thông qua Bluetooth. Khi người sử dụng bị ngã, thiết bị sẽ phát hiện, sử dụng ứng dụng GreatCall trên điện thoại để gọi và gửi vị trí người bị ngã đến người thân hay người chăm sóc. Điểm hạn chế của ứng dụng là cần phải có

Hình 1.6 Hệ thống phát hiện ngã GreatCall Lively

điện thoại trong vùng phủ sóng và thiết bị phải được đặt trong bán kính kết nối với điện thoại qua Bluetooth thì hệ thống mới có thể gửi cảnh báo. Hệ thống có giá 49,99 USD (khoảng 1.160.000 VNĐ) và thuê bao hằng tháng là 14,99 USD (350 nghìn VNĐ/ tháng).



Hình 1.7 Hệ thống phát hiện ngã Buddi

Hệ thống phát hiện ngã có tên Buddi bao gồm một vòng đeo tay kết nối với điện thoại di động thông qua ứng dụng Buddi Connect, thiết bị này cho phép điều chỉnh độ nhạy của việc phát hiện ngã thông qua ứng dụng cài đặt trên di động. Cũng giống như hệ thống GreatCall Lively, vòng đeo tay cũng được kết nối với di động qua Bluetooth. Hệ thống cho phép gửi cảnh báo đến người thân trong gia đình với chi phí 2 bảng 1 tuần (khoảng 240 nghìn VNĐ/ tháng) hoặc gửi cảnh báo đến trung tâm hỗ trợ dịch vụ 24/7 với chi phí 4 bảng một tuần (khoảng 480 nghìn VNĐ/ tháng).



Hệ thống phát hiện ngã có tên Bay Alarm Medical có thể kết nối với điện thoại di động hay cố định. Hệ thống này gồm một thiết bị có hình dáng như mặt dây chuyền có thể phát hiện ngã và tự động gọi cảnh báo mà không cần bất kỳ sự can thiệp nào từ người dùng. Nó có khả năng kết nối với trạm tiếp nhận

Hình 1.8 Hệ thống phát hiện ngã Bay Alarm Medical

trong bán kính khoảng 240m hoặc gọi sự trợ giúp từ chuyên gia bằng kết nối 4G/LTE qua điện thoại 24/7. Dịch vụ y tế Bay Alarm có chi phí là 19,95 USD/ tháng (460 nghìn VNĐ/ tháng), ngoài ra có thể tăng lên nếu người sử dụng lựa chọn thêm dịch vụ hỗ trợ và chỉ hỗ trợ cho người dùng ở Mỹ.

Những hệ thống phát hiện ngã kể trên đều không hỗ trợ người dùng ở Việt Nam, kể cả nếu có hỗ trợ người dùng ở Việt Nam thì chi phí sử dụng cũng khá cao so với thu nhập bình quân của người Việt. Điều này đặt ra yêu cầu cần phát triển một hệ thống phát hiện VĐBT, tập trung vào ngã đáp ứng được các điều kiện, hoàn cảnh, nhu cầu, thu nhập của người dùng ở Việt Nam.

Bảng 1.2. So sánh các thiết bị phát hiện vận động bất thường đã được thương mại hóa

Hệ thống phát hiện ngã	Ưu điểm	Nhược điểm
Sentry	<ul style="list-style-type: none"> - Giá thành hợp lý - Đàm thoại hai chiều - Chế độ dẫn đường tới vị trí người bị ngã - Phạm vi sử dụng 800m 	<ul style="list-style-type: none"> - Chỉ hỗ trợ tại Mỹ - Yêu cầu có kết nối điện thoại cố định
SureSafe Go	<ul style="list-style-type: none"> - Định vị GPS - Cảnh báo tự động - Giám sát 24/7 - Phạm vi hoạt động lớn - Không yêu cầu kết nối cố định 	<ul style="list-style-type: none"> - Cần sạc năng lượng thường xuyên
Lively	<ul style="list-style-type: none"> - Chi phí thấp - Kết nối điện thoại di động qua Bluetooth 	<ul style="list-style-type: none"> - Phạm vi hoạt động khoảng 10m - Chỉ hỗ trợ tại Mỹ
Buddi	<ul style="list-style-type: none"> - Chi phí thấp 	<ul style="list-style-type: none"> - Cần sạc năng lượng thường xuyên

Hệ thống phát hiện ngã	Ưu điểm	Nhược điểm
	<ul style="list-style-type: none"> - Điều khiển qua ứng dụng điện thoại - Có thể điều chỉnh độ nhạy cảm biến 	
Bay Alarm Medical	<ul style="list-style-type: none"> - Thời gian sử dụng dài - Phạm vi hoạt động lớn, khoảng 244m - Có kết nối với điện thoại di động 	<ul style="list-style-type: none"> - Chi phí khá đắt đỏ - Độc quyền sử dụng đàm thoại với AT&T

1.4. Tập dữ liệu sử dụng

Chăm sóc sức khỏe sử dụng cảm biến trên cơ thể người nhận được sự quan tâm lớn từ các nhà nghiên cứu bởi ứng dụng thực tiễn của chúng như hệ thống chăm sóc sức khỏe thông minh. Trong lĩnh vực nhận dạng hoạt động ở người nói chung và phát hiện VĐBT nói riêng, cảm biến có vai trò như một trình điều khiển rất quan trọng, cảm biến giúp theo dõi chuyển động, môi trường và các thông số khác từ xa, dữ liệu từ cảm biến được truyền qua các giao thức thông dụng, đặc biệt là các giao thức không dây như WiFi, Bluetooth... Mặc dù có rất nhiều cách khác nhau để cảm biến có thể nhận dạng hoạt động, cách đơn giản nhất là chúng có thể đeo được trên cơ thể người.

Các cảm biến đang ngày càng phổ biến trên các thiết bị và vật dụng mà con người sử dụng hằng ngày, những cải tiến vượt bậc trong công nghệ chế tạo cảm biến đã cho ra đời những cảm biến có kích thước nhỏ, tiêu thụ ít năng lượng, có thể hoạt động bền bỉ và ít chịu ảnh hưởng bởi môi trường. Quan trọng hơn, các cảm biến có thể giao tiếp không dây với các thiết bị khác và có giá thành ngày một rẻ nên chúng đã trở nên thông dụng, các cảm biến thường được tích hợp vào các thiết bị thông minh để thu thập thông tin, tính toán, hay tương tác liên tục khi di chuyển. Các cảm biến

hiện nay khá phù hợp để mang theo người (cảm biến đeo), có thể sử dụng trong một thời gian dài mà ít gây phiền toái cho người dùng, sử dụng các cảm biến đeo sẽ không còn bị giới hạn trong những căn phòng với các thiết bị được thiết lập sẵn, chính điều này góp phần phát triển các ứng dụng trong nhận dạng hoạt động và chăm sóc sức khỏe.

Nổi bật trong số các cảm biến đeo được sử dụng để nhận dạng hoạt động ở người nói chung và phát hiện vận động bất thường nói riêng là các cảm biến quán tính bao gồm gia tốc kế (cảm biến gia tốc), con quay hồi chuyển và từ kế (cảm biến từ trường). Các cảm biến quán tính có ưu điểm nhỏ gọn, dễ mang theo, dễ thương mại hóa, do đó nó thường được tích hợp trên đồng hồ, điện thoại, nhẫn, tai nghe, kính mắt, mặt dây chuyền..., là những vật dụng thường được con người mang theo trong một thời gian dài. Tuy nhiên chúng cũng có nhược điểm là năng lượng tiêu thụ thường ảnh hưởng đến hiệu suất hoạt động của cảm biến trong trường hợp phải hoạt động liên tục và độ nhạy cảm với chuyển động cơ thể có thể dẫn đến nhận dạng sai hoạt động.

Các cảm biến quán tính được thiết lập trên những vị trí khác nhau của cơ thể người, thường là cổ tay (có trong đồng hồ thông minh), cổ chân (có trong giày thông minh) và thắt lưng (có trong điện thoại thông minh). Cảm biến gia tốc thu nhận sự thay đổi vị trí của cơ thể và có thể được kết hợp với con quay hồi chuyển để đo các chuyển động quay có sự phục hồi tư thế. Khi kết hợp cả hai cảm biến này có thể xác định chính xác một số hoạt động của con người như đi lên/xuống cầu thang, ngồi, đi bộ, chạy, nhảy. Các nhận dạng này có ý nghĩa quan trọng để xây dựng các ứng dụng liên quan đến phục hồi chức năng, dáng đi, bệnh lý khớp, bệnh Parkinson và phát hiện ngã. Ngoài ra, sự kết hợp giữa cảm biến gia tốc với cảm biến áp suất cũng có thể phát hiện chính xác ngã và hoạt động đi cầu thang.

Các cảm biến hình ảnh được sử dụng để ghi lại hoạt động, cảm xúc hoặc các ngữ cảnh khác nhau của con người. Tiêu biểu cho các loại cảm biến này có SenseCam, Sony Xperia eye, Microsoft Camera Kinect... Dữ liệu về các hoạt động hằng ngày của người dùng trong đó có ngã được các cảm biến này ghi lại, cùng với các dữ liệu về vị trí và được sử dụng cho các ứng dụng chăm sóc người cao tuổi tại nhà. Tuy

nhiên so với các công nghệ cảm biến khác, việc sử dụng các công nghệ cảm biến hình ảnh trong chăm sóc sức khỏe đặt ra các thách thức lớn về bảo mật, quyền riêng tư và khả năng lưu trữ dữ liệu.

Trong công nghệ cảm biến còn bao gồm các cảm biến môi trường như cảm biến nhiệt độ, độ ẩm, cảm biến chấn động, cảm biến khói.... Những cảm biến này được sử dụng nhiều trong các nghiên cứu về nhà thông minh, bệnh viện thông minh v.v. Ngoài ra một vài nghiên cứu còn sử dụng cảm biến sợi quang để phát hiện tư thế, điện trở đo áp lực để phát hiện các cơn co thắt cơ bắp. Tuy nhiên đối với bài toán phát hiện VDBT, các cảm biến này ít được sử dụng.

Một loại cảm biến khác đã xuất hiện trên một số sản phẩm đeo thương mại và các ứng dụng thu thập dữ liệu sức khỏe là cảm biến lai. Moves là một ứng dụng sử dụng dữ liệu gia tốc và GPS cho phép theo dõi việc di chuyển của người dùng bao gồm khoảng cách, tốc độ và vị trí. Các thiết bị đeo thương mại như Withings, Fibit Flex sử dụng những cảm biến này để đo số bước đi, khoảng cách di chuyển và lượng calorie tiêu thụ của người dùng, những dữ liệu này thường được đồng bộ với điện thoại qua bluetooth và có thể được chia sẻ với các ứng dụng có liên quan. Hiện nay cũng đã có một số thiết bị đeo mà điển hình như đồng hồ Apple Watch của Apple có khả năng phát hiện ngã, tuy nhiên giá thành thiết bị còn tương đối cao với người dùng ở Việt Nam, hơn nữa người dùng cần phải sử dụng các thiết bị khác trong “hệ sinh thái” của Apple như iPhone, iPad để đồng bộ hoá dữ liệu.

Tuy công nghệ cảm biến đã đạt được nhiều tiến bộ đáng kể, nhưng vẫn có những hạn chế nhất định. Kích thước của cảm biến tuy nhỏ nhưng khi được thiết lập trên cơ thể vẫn gây ra sự bất tiện trong việc theo dõi lâu dài. Các thiết bị đeo thương mại tuy nhiều nhưng đa số chúng vẫn chỉ được sử dụng cho các hoạt động thể dục thể thao, các sản phẩm này đơn giản là cung cấp các phép đo đã được xử lý như số bước đi, khoảng cách, lượng calorie tiêu thụ v.v., chưa có nhiều sản phẩm phát hiện VDBT, đặc biệt ở Việt Nam. Một số dữ liệu thô thu thập từ cảm biến trong các thiết bị như điện thoại, đồng hồ có nhiều nhiều do sự đa dạng của hoạt động, vị trí để thiết bị trên

người, vấn đề về pin và các tác động của môi trường tự nhiên. Vì vậy, việc xác thực các dữ liệu này vẫn còn là vấn đề mang nhiều thách thức.

Để có sử đánh giá khách quan và chính xác của giải pháp trong đề tài phát hiện vận động bất thường, phần này sẽ trình bày sơ lược về tập dữ liệu được sử dụng cho đề tài phát hiện vận động bất thường sử dụng cảm biến trong thiết bị đeo.

Do sự khan hiếm dữ liệu đối với chủ đề vận động bất thường, nhóm nghiên cứu đã tự tiến hành thu thập dữ liệu cho việc thử nghiệm mô hình. Thiết bị sử dụng cho việc thu thập dữ liệu bao gồm vi điều khiển ESP32, cảm biến gia tốc MPU6050, và tần số thu thập là 50Hz, kết hợp giao thức kết nối MQTT. Tập dữ liệu bao gồm 5 loại vận động, trong đó gồm 4 loại vận động bình thường như đứng yên, ngồi xuống, đứng lên và đi bộ; còn lại là vận động ngã với các tư thế ngã khác nhau. Độ dài tổng thể của tập dữ liệu là 2 giờ đồng hồ

1.5. Kết thúc chương 1

Trong chương này, nhóm đã đưa ra một cái nhìn tổng quan về bài toán phát hiện vận động bất thường, một chủ đề đang thu hút nhiều sự quan tâm trong lĩnh vực IoT. Đầu tiên, nhóm đã giới thiệu về khái niệm và tầm quan trọng của việc phát hiện các hoạt động bất thường, đặc biệt trong bối cảnh các hệ thống tự động và thông minh. Việc nhận dạng và phát hiện kịp thời các bất thường giúp ngăn chặn các rủi ro và bảo vệ an toàn cho con người và tài sản. Nhóm cũng đã nêu ra các thách thức kỹ thuật trong việc phát hiện bất thường, như sự đa dạng của dữ liệu, các yếu tố môi trường, cũng như yêu cầu về hiệu suất cao trong các hệ thống IoT. Tiếp theo, tổng quan về các cảm biến đã được trình bày, giúp nhóm hiểu rõ hơn về các công nghệ có thể sử dụng để nhận dạng hoạt động con người. Cuối cùng, nhóm nghiên cứu đã xem xét một số hệ thống phát hiện bất thường đã được thương mại hóa, cùng với việc thảo luận về tập dữ liệu được sử dụng trong các nghiên cứu và ứng dụng thực tế. Các kiến thức này sẽ làm nền tảng cho các chương sau, nơi nhóm đi sâu vào các phương pháp và kỹ thuật phát hiện bất thường cụ thể hơn.

CHƯƠNG 2 NGHIÊN CỨU THUẬT TOÁN VÀ CẢM BIẾN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG ỨNG DỤNG MÔ HÌNH TRÍ TUỆ NHÂN TẠO

2.1. Giới thiệu chung




Hình 2.1. Học máy trong bài toán phát hiện bất thường

Trong những năm gần đây sự phát triển vượt bậc của học máy (ML) đã mở ra nhiều hướng nghiên cứu mới và ứng dụng được vào nhiều lĩnh vực khác nhau. Một trong những ứng dụng quan trọng đó là phát hiện bất thường trên các dữ liệu. Sử dụng học máy có thể giải quyết được thách thức của việc xử lý lượng dữ liệu lớn và phức tạp từ các hệ thống IoT. Cụ thể, các thuật toán học máy có khả năng tự động phân tích dữ liệu từ các cảm biến trên các thiết bị đeo, giúp tự động hóa quá trình phát hiện sự bất thường. Lợi thế của việc ứng dụng học máy (ML) vào phát hiện bất thường trong hoạt động nằm ở việc có khả năng phân tích và xử lý lượng dữ liệu lớn, giúp tăng cường khả năng phát hiện các sự bất thường một cách chính xác và hiệu quả nhất. Ngoài ra, nếu kết hợp học máy (ML) vào các hệ thống IoT và thực hiện xử lý tại biên còn giúp xử lý dữ liệu tại chỗ trước khi truyền đến trung tâm. Điều này giúp giảm bớt gánh nặng cho hạ tầng mạng và giảm độ trễ trong việc đưa ra các quyết định quan trọng. Bằng cách phát hiện và xử lý các dữ liệu không bình thường ngay tại điểm thu thập, hệ thống có thể tự động áp dụng các biện pháp bảo vệ người sử dụng

hoặc thông báo cảnh báo mà không cần phải chờ đợi phản hồi từ trung tâm. Điều này đặc biệt hữu ích trong các ứng dụng đòi hỏi phản ứng nhanh, nơi mà mỗi giây đều quan trọng và mọi sự cố đều cần được xử lý ngay lập tức để tránh gây ra các hậu quả không mong muốn về người. Tuy nhiên, thách thức lớn nhất đối với việc triển khai các thuật toán học máy (ML) vào các hệ thống IoT tại biên là sự hạn chế về tài nguyên của các nút IoT. Thường thì các nút IoT được tích hợp từ các cảm biến có hạn chế về tài nguyên và được sử dụng cùng với các hệ thống nhúng có chi phí thấp. Các thuật toán học máy thường đòi hỏi khá nhiều tài nguyên tính toán và bộ nhớ để thực hiện quá trình huấn luyện và dự đoán. Tuy nhiên, các nút IoT thường chỉ có khả năng xử lý và lưu trữ hạn chế, điều này có thể làm giảm hiệu suất và độ chính xác của các thuật toán học máy khi triển khai trên các hệ thống IoT tại biên. Để vượt qua thách thức này, cần phải phát triển các phương pháp tiên tiến để tối ưu hóa việc triển khai thuật toán học máy trên các nút IoT, bao gồm cả việc tối ưu hóa thuật toán và quản lý tài nguyên hiệu quả.

Để khắc phục các hạn chế về tài nguyên và triển khai hiệu quả các thuật toán học máy trên các hệ thống IoT tại biên. Nhóm sẽ nghiên cứu và triển khai một mô hình học máy có thể phân biệt được các bất thường đối với các hoạt động thường của con người. Ứng dụng một số thuật toán như CNN và DNN để phân loại các sự cố bất thường dựa trên tập dữ liệu thu được từ các cảm biến trên thiết bị đeo.

2.2. Các cảm biến ứng dụng phát hiện vận động



Hình 2.2 Cảm biến gia tốc

Cảm biến gia tốc hay gia tốc kế (accelerometer) là một loại cảm biến quán tính được sử dụng nhiều trong thực tế bởi sự phù hợp của cảm biến này đối với việc theo dõi và nhận dạng hoạt động của con người. Gia tốc kế thu thập dữ liệu gia tốc chuyển động của thiết bị cũng như góc nghiêng so với phương nằm ngang (m/s^2). Với sự phát triển của công nghệ chế tạo cảm biến, các cảm biến gia tốc có kích thước ngày càng nhỏ, tiêu thụ ít năng lượng hơn, hiệu suất hoạt động được nâng cao, ít bị tác động bởi môi trường và đặc biệt, giá thành rẻ. Hơn nữa, việc sử dụng cảm biến gia tốc cũng mang lại cho người sử dụng cảm giác thoải mái hơn là dùng những cảm biến âm thanh hay hình ảnh, bởi nó đảm bảo tính riêng tư cần thiết cho người dùng.



Hình 2.3. Con quay hồi chuyển (trái), cảm biến con quay hồi chuyển LPY03(phải)

Con quay hồi chuyển (gyroscope) cũng là một loại cảm biến quán tính phổ biến. Đây là một cảm biến dùng để đo đạc hoặc duy trì hướng chuyển động (đơn vị tính là độ/giây - dps). Cảm biến này có nhiều ứng dụng trong thực tế như để định hướng chuyển động của tàu con thoi, duy trì sự ổn định của máy bay v.v. Con quay hồi chuyển thường được sử dụng cùng với gia tốc kế để đo chuyển động quay và sự phục hồi của tư thế. Sự kết hợp của hai cảm biến này có thể giúp xác định nhiều hoạt động của con người như đi bộ, chạy, nhảy, ngồi, đi lên cầu thang, đi xuống cầu thang, v.v. Trong chăm sóc sức khỏe, việc nhận dạng các hoạt động này rất có ích cho các ứng dụng giúp phục hồi chức năng, dáng đi, các bệnh về khớp, bệnh Parkinson và phát

hiện ngã. Hiện tại cũng có một hệ thống có tên SisFall để phát hiện ngã, các cảm biến được sử dụng gồm một cảm biến gia tốc MPU6050 (cấu hình $\pm 16g$, 13 bit của ADC), một cảm biến gia tốc có tên Freescale MMA8451Q (cấu hình $(\pm 8g, 14 \text{ bit của ADC})$ và một con quay hồi chuyển có tên ITG3200 ($\pm 20000 / s$, 16 bit của ADC, Texas Instruments). SisFall đạt được tỷ lệ phát hiện ngã tương đối cao.

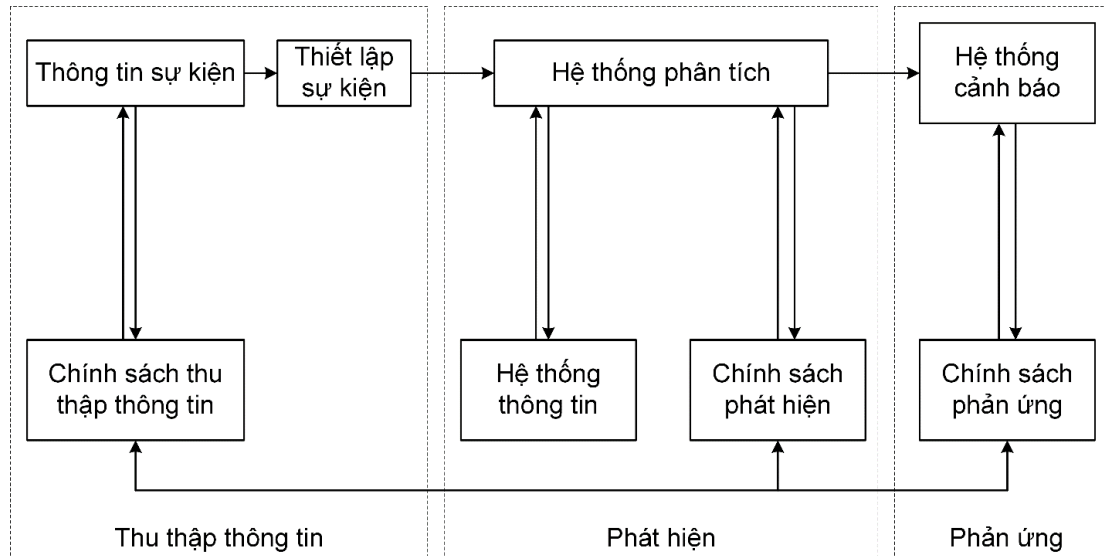
2.3. Sơ đồ tổng quát hệ thống phát hiện bất thường

Phát hiện bất thường là hành động xác định các đối tượng hoặc sự kiện mà chúng không hoạt động theo lẽ bình thường, khác biệt với những đối tượng còn lại. Hơn nữa, phát hiện bất thường từ lâu đã được ứng dụng trong việc phân tích và trích xuất các phần dữ liệu ngoại lai trong lĩnh vực khoa học dữ liệu. Phát hiện bất thường cũng được ứng dụng trong nhiều lĩnh vực khác nhau từ tài chính, chăm sóc sức khỏe, an ninh mạng, công nghiệp sản xuất...

Đối tượng bất thường có thể được chia thành ba loại: điểm dữ liệu bất thường, ngưỡng cảnh bất thường và tập hợp bất thường:

- Điểm dữ liệu bất thường: Đa số nghiên cứu tập trung vào điểm dữ liệu bất thường. Điểm dữ liệu bất thường đại diện cho sự kiện xảy ra ngẫu nhiên và không có sự lý giải cụ thể về nó.
- Ngưỡng cảnh bất thường: Một bất thường về ngưỡng cảnh, hay còn gọi là bất thường có điều kiện, là một dạng đối tượng dữ liệu mà có thể được coi là bất thường trong một vài tình huống cụ thể. Ngưỡng cảnh bất thường cần xác định cả về ngưỡng cảnh xảy ra và đặc trưng của sự kiện đó. Đặc trưng về ngưỡng cảnh thường là các mốc không-thời gian, trong khi đặc trưng về sự kiện là một dữ liệu mẫu mô tả về sự kiện đó.
- Tập hợp bất thường: Những tập hợp bất thường của các điểm dữ liệu riêng lẻ được gọi là ngoại lệ tập thể hoặc ngoại lệ nhóm, trong đó mỗi điểm dữ liệu khi xem xét riêng lẻ có vẻ như là các trường hợp dữ liệu bình thường, nhưng khi quan sát trong

một nhóm lại thể hiện những đặc điểm bất thường



Hình 2.4. Mô tả hệ thống phát hiện bất thường

Sơ đồ tổng quát của hệ thống phát hiện VDBT được thể hiện trong Hình 2.1. Một hệ thống phát hiện bất thường cơ bản hoạt động theo ba giai đoạn chính là: Thu thập thông tin, Phát hiện và Phản ứng. Trong giai đoạn Thu thập thông tin, dữ liệu được thu thập hoặc theo dõi từ cảm biến, nhật ký hoạt động của hệ thống hoặc các loại dữ liệu hoạt động khác. Các chính sách thu thập thông tin đại diện cho loại dữ liệu được thu thập, tần số lấy mẫu và điều kiện để kích hoạt bộ thu. Trong giai đoạn Phát hiện, một khi dữ liệu được thu thập và biến đổi thành một sự kiện, hệ thống bắt đầu quá trình phân tích mẫu dữ liệu này theo chính sách phát hiện được cài đặt trong hệ thống. Chính sách phát hiện là yếu tố chính để phân loại một hệ thống phát hiện bất thường, chính sách được sử dụng có thể là các luật được cài đặt cứng hay các thuật toán để xác đặc trưng của dữ liệu, từ đó đưa ra quyết định xem dữ liệu đó là bình thường hay bất thường. Cuối cùng, giai đoạn Phản ứng tiếp nhận kết quả và đưa ra những cảnh báo kịp thời cho người sử dụng hoặc trung tâm quản lý.

Như đã đề cập bên trên, để có thể phân loại một hệ thống phát hiện bất thường, ta có thể sử dụng phương thức cũng như chính sách khi phân tích một mẫu dữ liệu, từ đó ta chia hệ thống phát hiện bất thường theo hai hướng: sử dụng các phương pháp truyền thống và sử dụng phương pháp thông minh. Các hệ thống phát

hiện bất thường truyền thống bao gồm những phương pháp không sử dụng các thuật toán học máy hay học sâu phức tạp. Chúng thường áp dụng các mô hình thống kê, hệ thống dựa trên quy tắc, hoặc các kỹ thuật dựa trên khoảng cách để phát hiện các điểm bất thường. Những phương pháp này thường dễ triển khai và tiết kiệm tài nguyên tính toán hơn so với các phương pháp học máy hiện đại, nên rất phù hợp cho các tập dữ liệu nhỏ hoặc các tình huống ít phức tạp. Trái lại, các hệ thống phát hiện điểm bất thường thông minh sử dụng các kỹ thuật tiên tiến, thường bao gồm học máy (ML), học sâu (DL) và trí tuệ nhân tạo (AI), để nhận diện các điểm bất thường phức tạp và tinh vi. Khác với các hệ thống truyền thống, các hệ thống này có khả năng tự điều chỉnh, dựa trên dữ liệu và có thể xử lý các môi trường phức tạp, liên tục thay đổi. Những hệ thống này ngày càng quan trọng trong các lĩnh vực như an ninh mạng, tài chính, IOT và chăm sóc sức khỏe, nơi việc phát hiện các điểm bất thường theo thời gian thực là rất quan trọng.

Một điểm quan trọng nữa cần được xem xét tới là loại hình của dữ liệu đầu vào: chiều của dữ liệu (đơn hoặc đa chiều), số lượng đặc trưng hoặc bất cứ mối tương quan nào giữa các đối tượng dữ liệu. Đối với dữ liệu dạng chuỗi, các điểm dữ liệu thường là tuyến tính, mô tả về chuỗi các sự kiện một cách có trật tự. Dữ liệu loại này điển hình là dữ liệu theo thời gian, có thể là liên tục hoặc rời rạc. Dữ liệu có thể mô tả cả về không gian và thời gian như là hình ảnh hoặc video.

2.4. Một số thuật toán ứng dụng trong phát hiện vận động bất thường

Phát hiện bất thường đóng vai trò quan trọng trong quá trình xác định các mẫu ngoại lai hay hành động khác với bình thường, sau đây là một số thuật toán được sử dụng phổ biến.


2.4.1. Thuật toán phát hiện bất thường truyền thống

❖ Phương pháp thống kê

Phương pháp thống kê là một phương pháp dựa trên mô hình, trong đó mô hình được tạo từ những dữ liệu và đối tượng và mối tương quan lẫn nhau giữa chúng. Hầu hết sử dụng phương pháp thống kê trong phát hiện bất thường đều dựa

trên quá trình phát triển một mô hình phân bố xác suất và khả năng xuất hiện của đối tượng đối với mô hình xác suất đó. Trong phương pháp thống kê, một dữ liệu bất thường (hay còn gọi là ngoại lai) là một đối tượng có khả năng xuất hiện thấp. Nếu giả sử dữ liệu tuân theo phân bố Gauss, giá trị trung bình và độ lệch chuẩn của phân bố xác suất có thể được tính toán trực tiếp từ dữ liệu.

Phân bố Gauss, hay còn gọi là phân bố chuẩn là một trong những phân bố xác suất điển hình nhất trong thống kê. Phân bố Gauss gồm hai tham số chính là: giá trị trung bình μ và độ lệch chuẩn σ , ký hiệu là $N(\mu, \sigma)$.



Hình 2.5. Hàm mật độ xác suất (PDF) trong phân bố GAUSS

Khả năng rất thấp khi mà một đối tượng hoặc dữ liệu trong phân bố $N(0,1)$ sẽ nằm ở hai đầu của phân phối. Ví dụ, xác suất chỉ là 0.0027 rằng một đối tượng nằm ngoài khu vực trung tâm giữa ± 3 độ lệch chuẩn. Tóm lại, nếu c là một hằng số và x là giá trị thuộc tính của một đối tượng, thì xác suất $|x| \geq c$ sẽ giảm nhanh khi c tăng lên. Giả sử α là giá trị xác suất khi $|x| \geq c$. Bảng dưới đây hiển thị một số giá trị mẫu cho c và các giá trị tương ứng cho α khi phân phối là $N(0,1)$.

Bảng 2.1. Một số giá trị xác suất của phân bố GAUSS theo giá trị c

c	α
1.00	0.3173
1.50	0.1336

c	α
2.00	0.0455
2.50	0.0124
3.00	0.0027
3.50	0.0005
4.00	0.0001

Để xác định điểm giá trị bất thường hay không, nếu ta sử dụng giá trị c so với tâm của phân bố thì giá trị xác suất của giá trị c là một tiêu chí đánh giá khả năng bất thường của điểm dữ liệu này. Bất thường phân bố Gauss được tính dữ liệu tuân theo phân bố $N(\mu, \sigma)$, một đối tượng có thuộc tính trong phân bố là x là bất thường nếu $|x| \geq c$, với c là một hằng số được chọn khi $P(|x| \geq c) = \alpha$.

Để sử dụng định nghĩa ở trên, xác định một giá trị cho α là cần thiết. Các đối tượng bất thường cho thấy một giá trị từ một phân phối khác biệt, α biểu thị xác suất mà chúng ta vô tình phân loại một đối tượng từ phân phối cho trước là một ngoại lệ. Nếu một ngoại lệ là một giá trị hiếm gặp của phân phối $N(0,1)$, thì α đại diện cho mức độ hiếm có của giá trị đó. Bây giờ, nếu phân phối của một thuộc tính quan tâm đối với các đối tượng bình thường có phân phối Gaussian với trung bình là μ và độ lệch chuẩn là σ , tức là phân phối $N(\mu, \sigma)$, thì để sử dụng định nghĩa đã đề cập ở trên, ta phải chuyển đổi thuộc tính x thành một thuộc tính mới t , có phân phối $N(0,1)$. Cụ thể, ta thiết lập biến $t = \frac{x-\mu}{\sigma}$ (t thường được gọi là t -score). Ở đây, μ và σ là không xác định và được ước tính bằng cách sử dụng trung bình mẫu và độ lệch chuẩn mẫu S_x . Trên thực tế, phương pháp này hoạt động tốt khi kích thước dữ liệu lớn. Tuy nhiên, chúng ta lưu ý rằng phân phối của z thực ra không hoàn toàn là $N(0,1)$.

❖ Phương pháp dựa trên khoảng cách

Từ định nghĩa, việc xác định một đối tượng bất thường là tìm ra điểm dữ liệu khác biệt so với những điểm còn lại. Một trong những phương pháp phổ biến và đơn giản nhất là tính toán được khoảng cách giữa từng điểm và tập hợp các điểm. Ý tưởng chính trong phương pháp này là những điểm dữ liệu bất thường thông thường có vị trí tách biệt ra khỏi một tập, một nhóm dữ liệu khác. Đây là một công cụ mạnh mẽ để phát hiện các mô hình bất thường trong các lĩnh vực khác nhau như an ninh mạng, tài chính, chăm sóc sức khỏe và giám sát công nghiệp. Tuy nhiên, điều chỉnh cẩn thận

các tham số (như số lượng lân cận hoặc ngưỡng khoảng cách) và có thể cần tính toán chuyên sâu cho các tập dữ liệu lớn là vô cùng cần thiết. Bất chấp những thách thức này, các thuật toán dựa trên khoảng cách vẫn là một lựa chọn phổ biến do tính linh hoạt và hiệu quả của chúng trong các nhiệm vụ phát hiện sự bất thường trong thế giới thực.

Giả sử \mathcal{D} đại diện cho tập dữ liệu n -chiều, trong không gian liên tục không giới hạn \mathcal{R}^n . Những điểm dữ liệu trong \mathcal{D} được ký hiệu là p, q , và $d(p, q)$ là khoảng cách giữa hai điểm dữ liệu tương ứng.

Bắt đầu với một thuật toán dựa trên khoảng cách đơn giản nhất, ta cần làm rõ ba vấn đề chính sau:

1. Phương pháp đo: Cho biết mức độ bất thường của điểm dữ liệu. Cách thức tính toán khoảng cách giữa hai điểm dữ liệu là gì?
2. Khẳng định: Kết quả điểm dữ liệu có phải bất thường hay không? Có thể xác định một giá trị ngưỡng nhằm làm tiêu chí cho mức độ bất thường của điểm dữ liệu.
3. Tương quan: Điểm dữ liệu này có “bất thường hơn” điểm dữ liệu kia hay không?

Các phép đo độ tương tự phổ biến bao gồm các phép đo trực tiếp như khoảng cách Euclid, Minkowski và Mahalanobis. Ngoài ra, các phép đo khác như độ tương đồng cosine và chỉ số Jaccard cũng được sử dụng; thường thì các phép đo gián tiếp, chẳng hạn như Lân cận gần nhất chung (SNN), lại phù hợp hơn.

$$d_{Mahalanobis} = \sqrt{(p - q)^T S^{-1} (p - q)} \quad (2.1)$$

$$d_{Minkowski} = \min_{i=1}^d |p_i - q_i| \quad (2.2)$$

$$d_{Euclid} = \sqrt{\sum_{i=1}^d (p_i - q_i)^2} \quad (2.3)$$

Thuật toán đơn giản nhất khi sử dụng khoảng cách giữa các điểm dữ liệu dựa trên sử giả định về phân bố dữ liệu, tức là dữ liệu là một chiều và được phân bố chuẩn với giá trị trung bình μ và độ lệch chuẩn σ . Khoảng cách với tâm phân bố càng lớn đồng nghĩa với khả năng xuất hiện của điểm dữ liệu đó càng thấp. Bởi vì có xác suất thấp nên điểm có khoảng với tâm phân bố lớn như vậy có khả năng trở thành một đối tượng bất thường. Một cách cụ thể hơn, khi giá trị z tăng, số lượng điểm dữ liệu tại khoảng cách $z\sigma$ so với tâm μ giảm nhanh chóng. Ví dụ chỉ khoảng 0.1% điểm dữ liệu vượt quá $\mu + 3\sigma$, và có thể áp dụng điều này để điều chỉnh tiêu chí bất thường cho điểm dữ liệu: Nếu một điểm dữ liệu z càng lớn nghĩa là càng cách xa so với tâm của phân bố (trung bình), thì đó là điểm bất thường.

Trong các phần trước, số lượng điểm dữ liệu trong một bán kính cố định đã được sử dụng để xác định mức độ bất thường. Tuy nhiên, có thể lập luận rằng một điểm là bất thường nếu các lân cận của nó ở rất xa hay nó cách xa các lân cận của nó. Nghĩa là, một tiêu chí độ ngoại lệ có thể được mô tả dựa trên khoảng cách đến các lân cận của nó. Trong nghiên cứu của Ramaswamy và cộng sự, khoảng cách k-NN (k-Nearest Neighbors) của một điểm được sử dụng làm điểm số ngoại lệ của nó. Giả sử lân cận gần nhất thứ k của một điểm p được ký hiệu là $NN(p, k)$, và tính khoảng cách $d(p, NN(p, k)) = d_k(p)$. Giá trị $d_k(p)$ càng lớn cho thấy rằng p có độ bất thường càng cao. Các giá trị $d_k(p)$ được xếp theo thứ tự giảm dần và các điểm tương ứng với các giá trị cao nhất sẽ được coi là bất thường. Mô tả chi tiết về thuật toán này được trình bày trong Thuật toán “k-NN outlier”.

Thuật toán: k-NN

Đầu vào: k, n, \mathcal{D} .

Đầu ra: Tập O gồm n điểm dữ liệu bất thường.

1. Xét $O = \emptyset$.
 2. Với mỗi $p \in \mathcal{D}$:
 3. $N_p = 0$
 4. $\forall q \in \mathcal{D} \mid q \neq p$:
 5. Nếu $|N_p| < k$ thì:
 6. Thêm q vào N_p
-

-
7. không:
 8. Nếu $\max(d(p, s) | s \in N_p) > d(p, q)$ thì:
 9. Thêm q vào N_p và loại bỏ s .
 10. $NN(p, k) = \max(d(p, s) | s \in N_p)$
 11. Với mỗi $p \in \mathcal{D}$:
 12. Nếu $|O| < k$ thì:
 13. Thêm p vào O
 14. không:
 15. Nếu $\min(NN(s, k) | s \in O) < NN(s, k)$ thì:
 16. Thêm p vào O và loại bỏ s
 17. Kết thúc.
-

Angiulli và Pizzuti [1] cho rằng tiêu chí xác định ngoại lệ của Ramaswamy và cộng sự không mang lại kết quả tốt, đặc biệt khi \mathcal{D} chứa nhiều cụm có mật độ khác nhau. Họ đề xuất rằng một thước đo ngoại lệ phù hợp hơn là trọng số của p được định nghĩa như sau:

$$\sum_{i=1}^k d_i(p)$$

Như bên trên, các giá trị trọng số này được sắp xếp theo thứ tự giảm dần để tìm ra các điểm bất thường nhất

2.4.2. Thuật toán phát hiện VDBT thông minh sử dụng mô hình học máy

Các kỹ thuật hướng dữ liệu thường liên quan đến các phương pháp học máy, trong đó vai trò của một mô hình toán học không còn là chủ đạo và được bù đắp bằng sự sẵn có của một lượng lớn dữ liệu, từ đó có thể "học" được những thông tin hữu ích. Học máy là một lĩnh vực nghiên cứu rộng lớn với nhiều ứng dụng khác nhau. Thông thường, nó được phân thành ba nhóm chính: học có giám sát (supervised learning), học không giám sát (unsupervised learning) và học tăng cường (reinforcement learning). Tuy nhiên, cũng có những sự kết hợp khác như học bán giám sát (semi-supervised learning). Hơn nữa, với những tiến bộ về công nghệ, học sâu (deep learning) cũng đang ngày càng phát triển mạnh mẽ. Nhiều kỹ thuật học máy thường áp dụng phương pháp học sâu hoặc được kết hợp với học sâu để cải thiện hiệu quả.

- Học có giám sát: mô hình hóa cả dữ liệu bình thường và bất thường, yêu cầu dữ liệu được gán nhãn chi tiết.
- Học không giám sát: xác định bất thường mà không cần biết trước về chi tiết dữ liệu đầu vào.
- Học bán giám sát: chỉ dữ liệu bình thường được mô hình hóa, dữ liệu bất thường được xác định bởi giá trị ngưỡng khác với bình thường.

Học có giám sát liên quan tới kỹ thuật học máy huấn luyện một mô hình, trong đó áp dụng một tập dữ liệu tham khảo cho đầu ra tương ứng. Ứng dụng học có giám sát trong phát hiện bất thường có một số trở ngại so với các mục đích ứng dụng học có giám sát khác. Trong thực tiễn, những dữ liệu mẫu hiếm gặp thường xuất hiện ít hơn trong quá trình huấn luyện. Ta có thể tùy chỉnh thuật toán cho trường hợp mất cân bằng dữ liệu như ở trên, từ đó tăng mức độ ảnh hưởng của những dữ liệu bất thường đối với mô hình. Phổ biến nhất là sử dụng phương pháp học có giám sát theo trọng số. Dữ liệu huấn luyện có thể được tái gán nhãn theo trọng số. Kỹ thuật học có giám sát thể hiện độ tin cậy cao nhờ vào việc "sự thật nền tảng" được đại diện bởi dữ liệu đã được gán nhãn trước. Tuy nhiên, trong nhiều hệ thống thực tế, thông tin này chỉ có sẵn một phần hoặc hoàn toàn không có. Việc giới thiệu các phương pháp học bán giám sát và không giám sát đã giúp khắc phục nhược điểm này.

Học bán giám sát có đôi nét tương đồng với học có giám sát, nhưng nó chỉ cần một số ít dữ liệu đã được gán nhãn trước, phần dữ liệu còn lại hoàn toàn không được gán nhãn. Bởi vì không được gán nhãn một cách tường minh, loại dữ liệu này có thể thu thập được từ thế giới thực thông qua một số thủ tục hoặc tách rời khỏi dữ liệu bình thường trong một lượng lớn dữ liệu. Mặc dù học bán giám sát là lựa chọn tốt nhất khi chỉ có một lượng nhỏ dữ liệu được gán nhãn, nhưng phương pháp này vẫn tồn tại một số hạn chế do các giả định liên quan đến việc sử dụng dữ liệu chưa gán nhãn. Những giả định này dựa trên mối quan hệ giữa nhãn và phân phối của dữ liệu chưa gán nhãn, do đó các giả định sai có thể dẫn đến hiệu suất kém.

Ngược lại với hai phương pháp trên là học không giám sát, học không giám sát học từ dữ liệu mà đầu ra tương ứng của nó không được biết trước. Với học không

giám sát, không cần đến tiền gán nhãn dữ liệu cho mô hình học máy, giảm thiểu đáng kể chi phí triển khai. Nguyên lý hoạt động cơ bản của học không giám sát dựa trên giả định rằng dữ liệu bất thường hiếm khi xuất hiện và khác biệt hoàn toàn so với phần còn lại. Thuật toán phổ biến là phân cụm, trong đó dữ liệu bất thường không thuộc bất kỳ một cụm nào hoặc cụm đó chỉ là thiểu số so với nhiều cụm còn lại. Nhược điểm chung của ba phương pháp trên là khả năng thích ứng với thay đổi thấp, trừ khi mô hình nhận được sự can thiệp từ bên ngoài. Do đó, những phương pháp như học tăng cường hay học sâu xuất hiện như một giải pháp vô cùng hiệu quả cho hầu hết các bài toán.

Một cách tiếp cận khi học từ những sự tương tác, được gọi là học tăng cường, đây là phương pháp tương đồng nhất đối với quá trình học của con người, tập trung vào việc ánh xạ hành động và từng tình huống để đạt được kết quả tối ưu nhất. Thành phần chính trong mô hình học tăng cường được gọi là một đối tượng phần mềm có thể thực hiện hành động và môi trường bao quanh đối tượng đó. Trạng thái của môi trường bị ảnh hưởng bởi những hành động, hành vi gây ra bởi đối tượng phần mềm. Trong học tăng cường tồn tại một giá trị gọi là giá trị thưởng, mục tiêu chính là tối đa hóa giá trị thưởng đạt được trong suốt quá trình hoạt động của mô hình. Điểm khác biệt của học tăng cường so với các loại hình học khác là sự độc lập với giám sát và tập trung vào việc ra quyết định nhằm đạt được một mục tiêu cụ thể. Học tăng cường thường được sử dụng trong các kịch bản IoT (Internet of Things) với môi trường đa tác nhân. Nó có thể được áp dụng để tạo ra một hệ thống có khả năng thích nghi với môi trường xung quanh.

Cuối cùng là học sâu, học sâu (deep learning) được phát triển từ mạng nơ-ron nhân tạo truyền thống (ANN). Về mặt kiến trúc, điểm khác biệt của học sâu là các lớp ẩn có chiều sâu hơn so với các ANN truyền thống, vốn chỉ có vài lớp ẩn (mạng nông). Các lớp bổ sung này cho phép học sâu có khả năng học từ một lượng lớn dữ liệu. Một sự khác biệt khác là trong các mô hình học máy truyền thống, các đặc trưng (features) thường được trích xuất thủ công từ dữ liệu đầu vào trước khi đưa vào mạng để tiến hành quá trình học. Trong học sâu, các đặc trưng của dữ liệu

đầu vào được tự động học qua nhiều lớp mạng. Học sâu có thể được áp dụng theo cả phương pháp có giám sát (supervised) và không giám sát (unsupervised). Các nghiên cứu gần đây đã áp dụng học sâu để phát hiện bất thường trong các hệ thống cảm biến. Nhiều loại mạng học sâu đã được đề xuất như Mạng Nơ-ron Tích chập (CNN), autoencoder, Máy Boltzmann Hạn chế (Restricted Boltzmann Machine), và Mạng Nơ-ron Hồi quy (RNN).

2.5. Các tham số đánh giá hiệu năng

Phát hiện bất thường là quá trình xác định dữ liệu sai trong các tập dữ liệu lớn, nhằm cải thiện chất lượng xử lý dữ liệu tiếp theo. Phương pháp phát hiện bất thường sẽ phân loại dữ liệu thành các giá trị bình thường và bất thường. Việc lựa chọn phương pháp phát hiện tốt nhất phụ thuộc rất nhiều vào đặc điểm của tập dữ liệu. Do đó, cần các tham số để đánh giá hiệu suất của các phương pháp khác nhau trên một tập dữ liệu nhất định.

Thông thường, để đánh giá chất lượng của quá trình phân loại, ma trận nhầm lẫn (confusion matrix), hoặc một số liệu dẫn xuất từ nó được sử dụng. Các loại tham số này cho kết quả tin cậy đối với tập dữ liệu không có đơn vị liên quan đến thời gian. Bảng ma trận nhầm lẫn tóm tắt hiệu suất của các thuật toán phân loại. Ma trận nhầm lẫn cơ bản bao gồm bốn loại số liệu chính được sử dụng để định nghĩa các thông số đánh giá của bộ phân loại:

1. Khẳng định đúng (TP – True Positive): TP đại diện cho các kết quả của mô hình khi cho dữ liệu đầu vào, và kết quả đầu ra đúng với nhãn mà nó được gán. Ví dụ đối với bài toán phát hiện bất thường thì kết quả của một dữ liệu bình thường khi qua mô hình sẽ trả lại kết quả là bình thường.
2. Phủ định đúng (TN – True Negative): TN đại diện cho các kết quả của mô hình dự đoán dữ liệu phủ định là phủ định. Trong ví dụ phát hiện bất thường, TN là số các dữ liệu bất thường được dự đoán là bất thường.
3. Khẳng định sai (FP – False Positive): FP đại diện cho các kết quả mà các dữ liệu sai nhưng mô hình dự đoán là đúng. Trong bài toán phát hiện bất

thường, FP là số các dữ liệu thực tế là bất thường nhưng kết quả trả về là bình thường.

4. Phủ định sai (FN – False Negative): FN đại diện cho các kết quả mà các dữ liệu đúng nhưng mô hình dự đoán là sai. Trong bài toán phát hiện bất thường, FN là số các dữ liệu thực tế là bình thường nhưng mô hình trả về kết quả là bất thường.

		Dự đoán	
		Bình thường	Bất thường
Thực tế	Bình thường	TP	FN
	Bất thường	FP	TN

Ngoài ma trận nhầm lẫn dùng để đánh giá hiệu năng của mô hình, các tham số được tính toán từ ma trận nhầm lẫn cũng đóng một vai trò quan trọng trong quá trình đánh giá.

- Accuracy: Tỷ lệ dự đoán chính xác tổng quát của mô hình (cả bất thường và bình thường). $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$

- Precision: Tỷ lệ dự đoán chính xác trường hợp bình thường của dữ liệu.

$$Precision = \frac{TP}{TP + FP}$$

- Recall: Hay còn gọi là độ nhạy – là tỷ lệ dự đoán chính xác các dữ liệu mà kết quả của mô hình dự đoán là bình thường trong tổng số các dữ liệu so với tổng số các dữ liệu bình thường trong toàn bộ tập dữ liệu.

$$Recall = \frac{TP}{TP + FN}$$

- F1-Score: Là giá trị được tổng hợp từ Precision và Recall.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

2.6. Kết luận chương 2

Trong chương này, nhóm đã nghiên cứu các thuật toán và cảm biến được ứng dụng trong việc phát hiện vận động bất thường thông qua mô hình trí tuệ nhân tạo. Đầu tiên, chương đã giới thiệu tổng quan về các loại cảm biến thường được sử dụng trong việc nhận diện vận động, từ đó hiểu rõ vai trò của chúng trong hệ thống phát hiện bất thường. Nhóm cũng đã trình bày sơ đồ tổng quát của một hệ thống phát hiện bất thường, nhấn mạnh quy trình xử lý dữ liệu cảm biến - một bước quan trọng giúp tối ưu hóa độ chính xác của các thuật toán phát hiện. Những thuật toán này, bao gồm phương pháp thống kê, phương pháp dựa trên khoảng cách điểm dữ liệu, và các phương pháp học máy, đã được phân tích để đánh giá hiệu quả trong việc phát hiện các hoạt động không bình thường. Cuối cùng, các tham số đánh giá hiệu năng của hệ thống đã được đề cập, cung cấp nền tảng để lựa chọn và tối ưu hóa các giải pháp phát hiện phù hợp. Những kiến thức này sẽ là cơ sở để triển khai hệ thống phát hiện bất thường trong thực tế, đồng thời giúp cải thiện khả năng nhận diện thông qua việc áp dụng trí tuệ nhân tạo.


CHƯƠNG 3 PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG BẰNG HỌC SÂU

Học sâu bao gồm các phương pháp liên quan đến các mạng thần kinh, các mạng này giúp chúng ta có thể khai thác, xử lý được các thông tin từ nhiều lớp thông tin phi tuyến tính để trích chọn và phân loại đặc trưng. Các lớp thông tin thường được tổ chức theo thứ bậc với thông tin đầu vào là đầu ra của lớp trước. Hiện nay, các kỹ thuật học sâu đã có sự phát triển vượt trội so với các phương pháp học thủ công, truyền thống trong nhiều lĩnh vực như: Thị giác máy tính, nhận dạng âm thanh và xử lý ngôn ngữ tự nhiên,...

Trong lĩnh vực nhận dạng hoạt động ở người, việc sử dụng các kỹ thuật học sâu sẽ giúp tự động phát hiện các đặc trưng có liên quan đến hoạt động, đặc biệt là các hoạt động phức tạp được thực hiện liên tục và không có tính lặp lại. Do vậy, đã có nhiều nghiên cứu sử dụng học sâu cho nhận dạng hoạt động và đạt được các kết quả khả quan. Các nghiên cứu thường thực hiện theo nguyên tắc sử dụng các cảm biến thu nhận dữ liệu theo một chuỗi các mẫu liên tiếp theo thời gian, sử dụng các kỹ thuật học sâu mà điển hình là mạng học sâu nhân chập (CNN) với đầu vào là các chuỗi thời gian một chiều để có thể học các phụ thuộc giữa các mẫu dữ liệu đầu vào.

Tuy nhiên, chưa có nhiều nghiên cứu thành công trong việc sử dụng các kỹ thuật học sâu để phát hiện VĐBT, đặc biệt là các VĐBT phức tạp. Trong chương này nhóm sẽ trình bày các thử nghiệm sử dụng mạng CNN để phát hiện VĐBT.

3.1. Mô hình đề xuất



Hình 3.1 Mô tả tổng quan về hệ thống phát hiện VĐBT

3.1.1. Dữ liệu thu thập

Tập dữ liệu được thu thập thông qua vi điều khiển ESP32 kết hợp với cảm biến MPU6050 với tần số đọc là 50Hz. Sau mỗi lần đọc dữ liệu từ cảm biến MPU6050, vi điều khiển ESP32 sẽ đóng gói ba loại dữ liệu tương ứng với giá trị gia tốc trên trục không gian ba chiều $Oxyz$ thành một bản tin theo định dạng JSON. Sau đó bản tin JSON được chuyển tiếp tới máy tính để cá nhân để lưu trữ thành dữ liệu dạng bảng theo định dạng tệp CSV thông qua giao thức MQTT. Trong đề án, tôi tận dụng broker MQTT mã nguồn mở Mosquitto nhằm tối đa hóa khả năng truyền thông giữa vi điều khiển và máy tính cá nhân.


Bộ dữ liệu thu thập được có dung lượng 1 giờ 30 phút 49 giây, 1600 tệp định dạng CSV, gồm năm trạng thái hoạt động của con người. Cụ thể tập dữ liệu được trình bày trong Bảng ... Tập dữ liệu mô tả năm trạng thái cơ bản trong hoạt động của con người bao gồm: Đứng yên, Đi bộ, Ngồi xuống, Đứng lên và Ngã. Đặc biệt dữ liệu về trạng thái Ngã được thu thập theo nhiều góc và hướng ngã khác nhau nhằm cung cấp một bộ dữ liệu đầy đủ nhất cho quá trình trích xuất đặc trưng và huấn luyện mô hình tiếp theo.

Bảng 3.1. Chi tiết tập dữ liệu thu thập

STT	Trạng thái	Thời lượng	Dung lượng (MB)
1	Đứng yên	26 phút 40 giây	4.419
2	Đi bộ	26 phút 37 giây	4.418
3	Ngồi xuống	12 phút 6 giây	2.067
4	Đứng lên	12 phút 5 giây	2.064
5	Ngã	14 phút 20 giây	2.431

Trong quá trình thu thập dữ liệu, tiến hành phân chia dữ liệu cho hai quá trình huấn luyện và kiểm thử với tỉ lệ 80/20 cho mỗi trạng thái dữ liệu thu thập.

3.1.2. Tiền xử lý dữ liệu



Hình 3.2 Tiền xử lý dữ liệu thu thập

Việc lọc bỏ tín hiệu nhiễu thường được thực hiện ở bước tiền xử lý dữ liệu và thường độc lập với các mô hình học máy. Tuy nhiên, thuật toán lọc cần có một ngưỡng lọc để loại bỏ đi các tín hiệu nhiễu. Trong khuôn khổ của đề tài này, tôi sử dụng cảm biến quán tính đeo trên người do đó dữ liệu lấy được từ các cảm biến có thể bị nhiễu hoặc/và đôi khi bị mất (dropped). Trong trường hợp lý tưởng, nếu cảm biến gia tốc được thiết lập ở tần số lấy mẫu 50 Hz thì mỗi giây sẽ cho ra 50 mẫu với 3 giá trị trên 3 trục x , y , z . Nhưng trong thực tế, có nhiều yếu tố có thể gây ra sự mất mát các mẫu giá trị như sự ảnh hưởng của các vật dụng kim loại đặt giữa cảm biến và máy thu tín hiệu hoặc cũng có thể là do các tác động bên ngoài làm cho chuyển động của con người trở nên không bình thường. Ngoài ra, các cảm biến có thể tự sinh ra nhiễu tùy vào chất lượng chế tạo ra nó. Trong trường hợp như vậy, người ta thường sử dụng một ngưỡng cho bộ lọc để loại bỏ nhiễu, sau đó sinh ra giá trị phù hợp bù lại cho mẫu bị mất. Ở đây, các bộ lọc dữ liệu nhiễu bao gồm bộ lọc thông thấp để loại bỏ các mẫu có giá trị thấp bất thường và bộ lọc thông cao để loại bỏ các mẫu có giá trị cao bất thường (các tín hiệu thấp bất thường và cao bất thường không

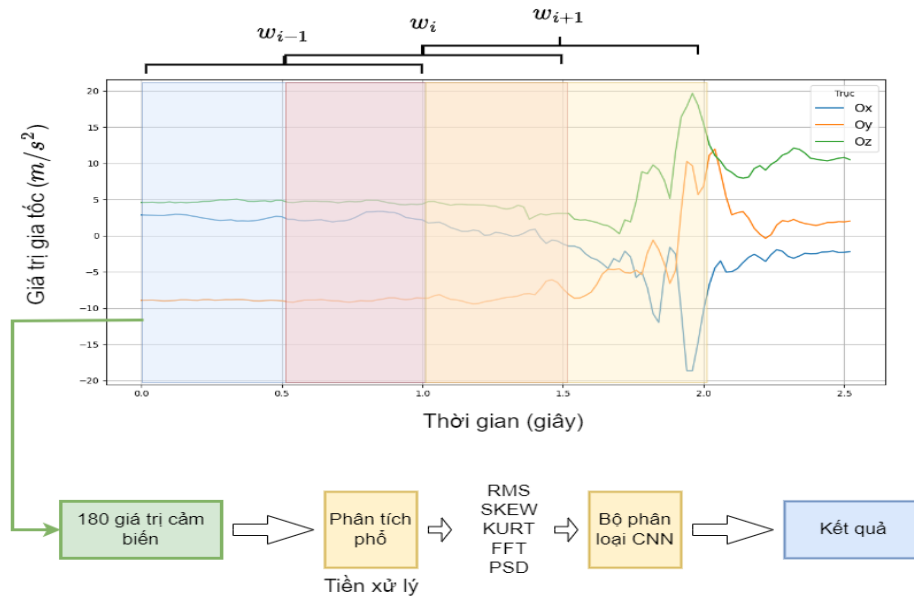
nằm trong ngưỡng sẽ không thể đi qua bộ lọc) thường được sử dụng. Sau đó, các mẫu được tô vào các khung hay cửa sổ thời gian. Nếu một khung chứa ít hơn một số lượng mẫu quy định (khoảng 75% số mẫu) so với thông thường, nó sẽ có thể bị loại bỏ bởi vì không đủ thông tin để phân lớp các vận động. Ngược lại, khung sẽ được lấy mẫu lại bằng cách sử dụng phương pháp nội suy Cubic Spline để bù vào mẫu bị mất. Đây là phương pháp nội suy được xây dựng tương tự như cách các kỹ sư thiết kế dùng một thiết bị có tên Spline để vẽ các đường cong sao cho đẹp và thẩm mỹ. Để vẽ các đường cong này, các kỹ sư sẽ xác định các điểm (nút) rồi bề cong thiết bị Spline qua những điểm này và tô theo, như vậy với sự hỗ trợ của thiết bị Spline, các kỹ sư sẽ vẽ được một đường cong mịn, không bị gãy khúc qua các điểm cần thiết.

Ngoài sử dụng bộ lọc thông thấp/cao, để nâng cao độ chính xác của tín hiệu cảm biến, trong các thử nghiệm NCS còn sử dụng thêm bộ lọc Kalman để lọc nhiễu. Đây là bộ lọc phù hợp với các tín hiệu rời rạc và tuyến tính, do bộ lọc sử dụng chuỗi gồm nhiều giá trị đo lường, các giá trị này chịu ảnh hưởng bởi nhiễu hoặc sai số để ước lượng biến số giúp nâng cao sự chính xác so với việc sử dụng một giá trị đo lường. Điểm nổi bật của bộ lọc Kalman là nó có thể ước tính trạng thái quá khứ, hiện tại và ngay cả tương lai một cách hiệu quả, bộ lọc này cũng có thể hoạt động tốt ngay cả trong trường hợp độ chính xác thực sự của mô hình còn chưa biết. Đây là bộ lọc được dùng nhiều trong các ứng dụng định hướng, định vị hay điều khiển các phương tiện di chuyển, bộ lọc Kalman cũng được sử dụng trong lĩnh vực xử lý tín hiệu, thậm chí trong các lĩnh vực kinh tế. Hình 2.2 mô tả tín hiệu gốc thu được từ gia tốc kế (đường màu xanh) và tín hiệu sau khi lọc nhiễu (đường màu vàng). Hình bên trên là tín hiệu khi sử dụng bộ lọc thông thấp (Low-pass filter) và hình bên dưới là tín hiệu khi sử dụng bộ lọc Kalman.

3.1.3 Trích chọn đặc trưng

Dữ liệu thô từ cảm biến chứa nhiễu hoặc dữ liệu sai lệch. Để chuẩn đổi dữ liệu sang dạng bảng, ta áp dụng phương pháp của sổ trượt. Cụ thể, dữ liệu thu được từ hai cảm biến ở tốc độ lấy mẫu 50Hz, kích thước của sổ trượt 2 giây, mỗi cửa sổ


sẽ bao gồm 400 điểm dữ liệu ($3 \text{ trục gia tốc } x,y,z \times 1 \text{ giây} \times 50 \text{ mẫu}$). Mỗi bước của sửa này di chuyển 1 giây để tạo một tập dữ liệu lớn hơn. Dữ liệu tiếp theo được xử lý sử dụng kỹ thuật FFT với tham số kích thước 128 mẫu và tần số 400 mẫu trên 1 giây. Quá trình này giúp trích chọn các đặc trưng từ dữ liệu gốc như: phổ công suất, RMS, độ lệch, và độ nhọn trong phân bố dữ liệu, áp dụng cho cả hai miền thời gian và tần số. Kết thúc quá trình tiền xử lý, ta thu được 207 đặc trưng từ bốn loại dữ liệu (x, y, z và A). Các đặc trưng tại miền thời gian bao gồm: RMS ($\times 1$), Độ lệch ($Skew \times 1$), Độ nhọn ($Kurtosis \times 1$). Các đặc trưng tại miền tần số bao gồm: Phổ công suất ($PSD \times 64$), Độ lệch ($Skew \times 1$), Độ nhọn ($Kurtosis \times 1$). Tóm lại, mỗi loại dữ liệu sẽ bao gồm 69 đặc trưng được trích xuất (3 ở miền thời gian và 66 ở miền tần số), do đó toàn bộ tập dữ liệu sẽ bao gồm $3 \times 69 = 207$ đặc trưng.



Hình 3.3 Quá trình huấn luyện mô hình

3.1.4 Mô hình học sâu

Đây được coi là phần cốt lõi của hệ thống phát hiện bất thường vận động bất thường thông minh. Về mô hình học sâu, tôi sử dụng mô hình CNN kết hợp với mạng nơ-ron kết nối đầy đủ để trích xuất và phân loại dữ liệu thành các trạng thái đã gán nhãn trước đó.



Hình 3.4. Trực quan hóa mô hình học sâu phát hiện VDBT

Các thành phần chính trong mô hình CNN bao gồm:

- Lớp tích chập: chứa một tập các bộ lọc có thể “học”, gọi là nhân, là các ma trận kích thước nhỏ, trượt qua toàn bộ dữ liệu đầu vào và tính toán các điểm giữa trọng số của bộ lọc và giá trị dữ liệu tương ứng.
- Lớp kích hoạt: Bằng việc thêm hàm kích hoạt vào vào đầu ra của lớp tích chập, các lớp kích hoạt thêm tính phi tuyến vào mạng CNN.
- Lớp gộp: Lớp này được thêm vào định kỳ vào trong mạng CNN, chức năng chính của lớp gộp là giảm kích thước của kết quả giúp tăng tốc độ tính toán, ngoài ra nó cũng đảm bảo tránh bị overfitting.
- Lớp phẳng: Kết quả của ma trận đặc trưng được chuyển đổi thành dạng một chiều.
- Lớp nơ-ron kết nối đầy đủ: Từ kết quả của các lớp trước để tính toán kết quả phân loại cuối cùng hoặc thực hiện nhiệm vụ hồi quy.

CNN khác với các thuật toán học máy cổ điển ở chỗ nó có khả năng tự động trích xuất được các đặc trưng của dữ liệu với quy mô lớn, ta có thể bỏ qua quá trình tìm kiếm dữ liệu đặc trưng thủ công. Các lớp tích chập cho phép CNN các đặc tính bất biến dịch, cho phép nó xác định và trích xuất các mẫu cũng như đặc trưng từ dữ liệu bất kể các biến thể về vị trí, hướng, tỷ lệ hoặc dịch thuật. Không chỉ được ứng dụng trong việc phân loại hình ảnh, CNN rất linh hoạt và được ứng dụng trong nhiều lĩnh vực khác như xử lý ngôn ngữ tự nhiên, phân tích dữ liệu theo thời gian và nhận dạng giọng nói. Hơn nữa, để có thể phù hợp khi triển khai trên các thiết bị nhúng, mô hình dựa trên CNN là cần thiết. Mô hình CNN thích hợp cho việc phân loại hình ảnh, âm thanh và dữ liệu từ cảm biến như cảm biến gia tốc. Thêm vào đó,

CNN không yêu cầu nhiều trong quá trình tiền xử lý dữ liệu, quá trình trích chọn đặc trưng hoàn toàn tự động mà không cần sự tinh chỉnh thủ công so với các loại mô hình truyền thống khác. Ngoài ra, trong mô hình học sâu đề xuất, tôi có sử dụng thêm mạng nơ-ron kết nối đầy đủ, điều này giúp mô hình có thể học mối tương quan giữa các đặc trưng được trích ra bởi mạng CNN. Chi tiết thông số cài đặt cho từng lớp trong mô hình học sâu phát hiện vận động bất thường được trình bày trong Bảng 3.2.

Bảng 3.2. Chi tiết mô hình học sâu phát hiện VDBT

Lớp	Tham số	Định nghĩa
Đầu vào	207	Số lượng các đặc trưng đầu vào
Reshape	23 cột	Chuyển mảng đặc trưng đầu vào thành dạng dữ liệu đa chiều.
1D-Conv	32	Số lượng bộ lọc sử dụng trong lớp tích chập
	3	Kích thước bộ (nhân) sử dụng trong lớp tích chập
	1	Số lượng lớp tích chập
Gộp giá trị lớn nhất (Max)	2-2	Chọn giá trị lớn nhất trong 2 giá trị với bước nhảy là 2.
Lớp phẳng		Chuyển dữ liệu đa chiều sang đơn chiều (Sau khi dữ liệu đi qua mạng tích chập cần “làm phẳng” để trở về trạng thái ban đầu).
Lớp nơ-ron kết nối đầy đủ	32	Mạng nơ-ron kết nối đầy đủ gồm 32 nút.
Loại bỏ (dropout)	0.1	Ngẫu nhiên loại bỏ một nốt của mạng nơ-ron nhằm giảm nguy cơ mô hình bị overfitting.
Lớp nơ-ron kết nối đầy đủ	16	Mạng nơ-ron kết nối đầy đủ gồm 16 nút.
Đầu ra	5	Phân loại kết quả trạng thái từ dữ liệu đầu vào: gồm 5 trạng thái.

3.2. Thực hiện mô hình

Trong quá trình huấn luyện mô hình, tôi chia ngẫu nhiên tập dữ liệu thành hai phần: 80% cho quá trình huấn luyện và 20% cho quá trình kiểm thử và đánh giá. Như trong Hình 3.3, đầu vào của mô hình sẽ bao gồm 207 giá trị đặc trưng từ tập dữ liệu đã qua xử lý. Sau đó, chuyển đổi chúng thành cấu trúc dữ liệu

phù hợp với yêu cầu đầu vào của lớp tích chập. Cuối cùng kết quả đầu ra của mô hình là tập 5 trạng thái tương ứng với tên nhãn đã liệt kê trong Bảng 3.2. Quá trình triển khai và huấn luyện sử dụng TensorFlow và được tiến hành trên nền tảng Edge Impulse.

Nền tảng Edge Impulse là một nền tảng triển khai học máy dựa trên đám mây, nó hỗ trợ việc phát triển ứng dụng trí tuệ nhân tạo trên các hệ thống nhúng và biên có tài nguyên hạn chế. Nền tảng được xây dựng dựa trên các nguyên tắc về khả năng truy nhập, tối ưu trung tâm dữ liệu và cộng tác chéo ngăn xếp. Edge Impulse đã được sử dụng trong công nghiệp, nghiên cứu và giáo dục, học hỏi từ những ứng dụng triển khai này giúp tập trung vào các vấn đề có mức độ ảnh hưởng lớn hơn trong tương lai.

Sau quá trình huấn luyện và xác thực mô hình, tôi triển khai chúng trên một thiết bị nhúng, cụ thể ở đây là vi điều khiển ESP32-S3. Điều này cho phép mô hình có thể hoạt động mà không cần tới kết nối Internet, từ đó giảm độ trễ và hoạt động với mức tiêu thụ năng lượng tối thiểu. Nền tảng Edge Impulse giúp chuyển đổi mô hình học máy dưới dạng thư viện C++ kèm theo Edge Impulse SDK, giúp dễ dàng triển khai mô hình học máy vào trong ESP32-S3 hoặc bất cứ loại vi điều khiển hay máy tính nhúng nào khác.

Ngoài ra, khi xây dựng mô hình để triển khai, tôi có thêm vào các lớp tối ưu sử dụng trình biên dịch EON. Trình biên dịch EON cho phép sử dụng mạng nơ-ron nhân tạo với ít bộ nhớ RAM hơn, tiết kiệm bộ nhớ Flash hơn, trong khi vẫn duy trì được độ chính xác của mô hình ban đầu. Thêm vào đó, tôi có sử dụng thêm lượng tử hóa mô hình từ định dạng dữ liệu là số thực 32 bit (float32) về dạng số nguyên 8 bit (int8). Điều này giúp mô hình dễ dàng tích hợp vào vi điều khiển hơn vì vi điều khiển.

3.3. Kiểm thử và đánh giá

3.3.1 Các tham số đánh giá

Phát hiện bất thường là quá trình xác định dữ liệu sai trong các tập dữ liệu lớn, nhằm cải thiện chất lượng xử lý dữ liệu tiếp theo. Phương pháp phát hiện bất thường sẽ phân loại dữ liệu thành các giá trị bình thường và bất thường. Việc lựa

chọn phương pháp phát hiện tốt nhất phụ thuộc rất nhiều vào đặc điểm của tập dữ liệu. Do đó, cần các tham số để đánh giá hiệu suất của các phương pháp khác nhau trên một tập dữ liệu nhất định.

Thông thường, để đánh giá chất lượng của quá trình phân loại, ma trận nhầm lẫn (confusion matrix), hoặc một số liệu dẫn xuất từ nó được sử dụng. Các loại tham số này cho kết quả tin cậy đối với tập dữ liệu không có đơn vị liên quan đến thời gian. Bảng ma trận nhầm lẫn tóm tắt hiệu suất của các thuật toán phân loại. Ma trận nhầm lẫn cơ bản bao gồm bốn loại số liệu chính được sử dụng để định nghĩa các thông số đánh giá của bộ phân loại:

- Khẳng định đúng (TP – True Positive): TP đại diện cho các kết quả của mô hình khi cho dữ liệu đầu vào, và kết quả đầu ra đúng với nhãn mà nó được gán. Ví dụ đối với bài toán phát hiện bất thường thì kết quả của một dữ liệu bình thường khi qua mô hình sẽ trả lại kết quả là bình thường.
- Phủ định đúng (TN – True Negative): TN đại diện cho các kết quả của mô hình dự đoán dữ liệu phủ định là phủ định. Trong ví dụ phát hiện bất thường, TN là số các dữ liệu bất thường được dự đoán là bất thường.
- Khẳng định sai (FP – False Positive): FP đại diện cho các kết quả mà các dữ liệu sai nhưng mô hình dự đoán là đúng. Trong bài toán phát hiện bất thường, FP là số các dữ liệu thực tế là bất thường nhưng kết quả trả về là bình thường.
- Phủ định sai (FN – False Negative): FN đại diện cho các kết quả mà các dữ liệu đúng nhưng mô hình dự đoán là sai. Trong bài toán phát hiện bất thường, FN là số các dữ liệu thực tế là bình thường nhưng mô hình trả về kết quả là bất thường.

Bảng 3.3. Ma trận nhầm lẫn

		Dự đoán	
		Bình thường	Bất thường
Thực tế	Bình thường	TP	FN
	Bất thường	FP	TN

Ngoài ma trận nhầm lẫn dùng để đánh giá hiệu năng của mô hình, các tham số được tính toán từ ma trận nhầm lẫn cũng đóng một vai trò quan trọng trong quá trình đánh giá.

- Accuracy: Tỷ lệ dự đoán chính xác tổng quát của mô hình (cả bất thường và bình thường). $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$

- Precision: Tỷ lệ dự đoán chính xác trường hợp bình thường của dữ liệu.

$$Precision = \frac{TP}{TP + FP}$$

- Recall: Hay còn gọi là độ nhạy – là tỷ lệ dự đoán chính xác các dữ liệu mà kết quả của mô hình dự đoán là bình thường trong tổng số các dữ liệu so với tổng số các dữ liệu bình thường trong toàn bộ tập dữ liệu.

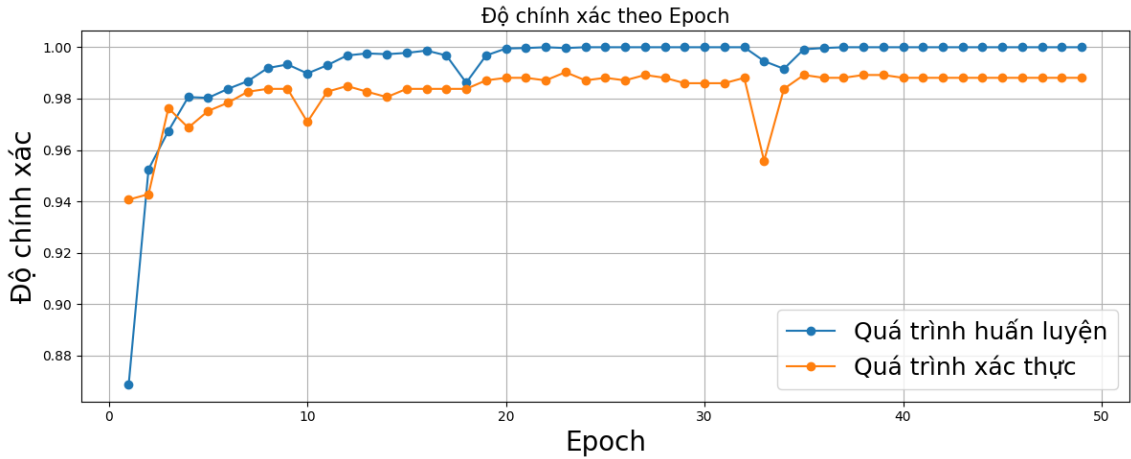
$$Recall = \frac{TP}{TP + FN}$$

- F1-Score: Là giá trị được tổng hợp từ Precision và Recall.


$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

3.3.2 Đánh giá hiệu năng hệ thống

Hình 3.4 mô tả độ chính xác của quá trình huấn luyện và quá trình xác thực mô hình với từng giá trị epoch. Bắt đầu từ epoch 1 tới 10, độ chính xác của quá trình huấn luyện và xác thực mô hình thay đổi nhanh từ 0% lên tới 98%. Từ epoch 6 trở đi, độ chính xác tiếp tục có sự tăng nhẹ và bão hòa tại 99%. Hình 3.5 mô tả độ mất mát tương ứng trong quá trình huấn luyện và xác thực mô hình. Từ epoch thứ 25 trở đi, mô hình đạt độ chính xác xấp xỉ 99.6% và độ chính xác khi xác thực là 98.6%, điều này chỉ ra rằng mô hình không bị thiên hướng lệch về một kết quả nào đó, hay còn gọi là overfitting. Trong khi đó, độ mất mát của mô hình tương ứng lần lượt là 0.02 và 0.05, mô hình có khả năng thích ứng tốt, có thể áp dụng cho những dữ liệu mới chưa biết.




Hình 3.4. Độ chính xác theo giá trị Epoch trong quá trình huấn luyện và xác thực

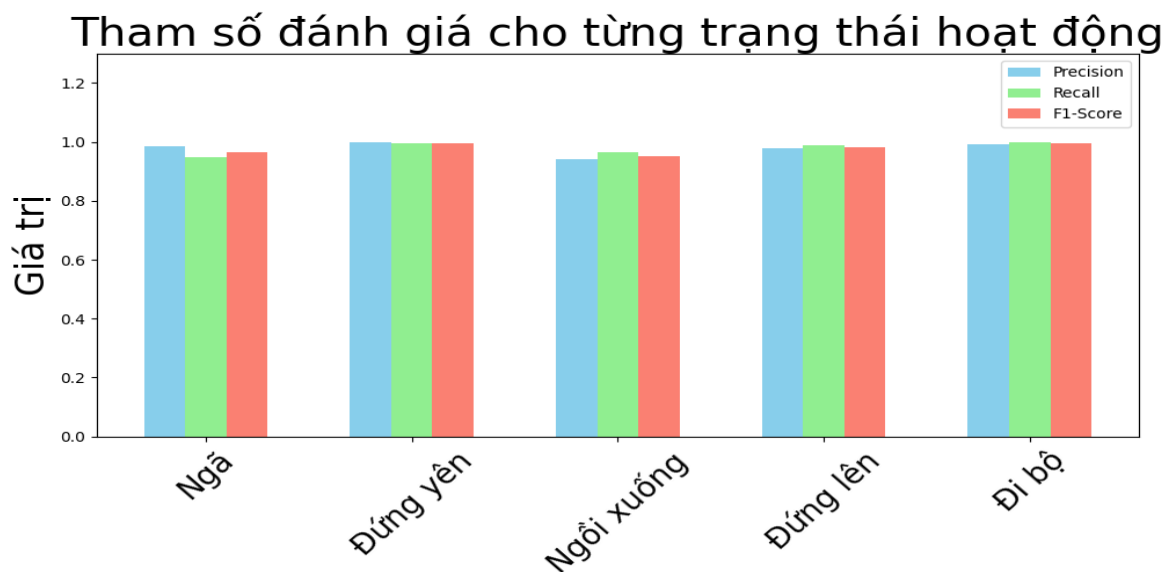


Hình 3.5 Giá trị mất mát theo giá trị Epoch trong quá trình huấn luyện và xác thực

Để đánh giá hiệu suất của mô hình hay thuật toán học máy một cách chi tiết hơn, tôi có sử dụng bảng ma trận nhầm lẫn. Ma trận nhầm lẫn là ma trận vuông dạng $N \times N$, trong đó N là số lượng nhãn có trong dữ liệu đầu vào. Ma trận nhầm lẫn được mô tả chi tiết trong Hình 3.12 của kiểm thử mô hình. Ngoài ra, một số thông số để đánh giá mô hình học máy được dẫn xuất từ ma trận nhầm lẫn như *accuracy*, *precision*, *recall*, và giá trị *F1*.



Hình 3.6. Ma trận nhầm lẫn của mô hình trong quá trình kiểm thử



Bảng 3.4. Tham số đánh giá cho từng loại dữ liệu

Nhãn	Precision	Recall	F1-Score
FALL	0.985	0.949	0.967
IDLE	0.998	0.996	0.997
SIT-DOWN	0.940	0.963	0.952
STAND-UP	0.977	0.998	0.995
WALK	0.992	0.998	0.995

3.4 Kết thúc chương 3

KẾT LUẬN

Sau quá trình làm đề án “*Nghiên cứu ứng dụng học máy để phát hiện vận động bất thường*”, quyền đề án đã trình bày bám sát nội dung của đề cương đã được duyệt bao gồm 3 chương:

- ✓ Chương 1: Tổng quan về theo dõi và cảnh báo sức khỏe lợn
- ✓ Chương 2: Phương pháp theo dõi và cảnh báo sức khỏe lợn
- ✓ Chương 3: Phát triển hệ thống theo dõi và cảnh báo sức khỏe lợn

Đề án đã đề xuất một mô hình AI phát hiện lợn được xây dựng qua các giai đoạn huấn luyện phát hiện, theo dõi, nhận diện và phát hiện bất thường hành vi lợn trong điều kiện tự nhiên tại các trang trại sử dụng học sâu. Ngoài ra, đề án đề xuất phương pháp phát hiện bất thường theo giai đoạn hoạt động, qua đó giảm thời gian theo dõi nhưng vẫn đảm bảo độ chính xác trong phát hiện bất thường. Các thực nghiệm đã được tiến hành trên các tập dữ liệu tự thu thập từ các trang trại lợn thương mại, với các kịch bản thực nghiệm khác nhau cho các kết quả khả quan. Điều này cho thấy tiềm năng của việc ứng dụng phương pháp trong thực tế, đặc biệt là chỉ cần sử dụng các thiết bị thông thường và rẻ tiền như camera giám sát. Thêm vào đó, đề án xây dựng mô hình PigAI nhằm phát hiện, nhận diện hành vi lợn có độ chính xác 99,3%. Mô hình theo dõi lợn có độ chính xác 93,6%. Có khả năng tái nhận diện cá thể lợn khi khuất tầm nhìn camera. Mô hình phân tích và cảnh báo bất thường về sức khỏe lợn dựa trên các dữ liệu hành vi lợn có độ chính xác 86,7% đến 93,8%.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] F. Angiulli, C. Pizzuti, “Fast outlier detection in high dimensional spaces,” in *Principles of Data Mining and Knowledge Discovery* (Springer, New York, 2002), pp. 15–27
- [2] Mubashir, M.; Shao, L.; Seed, L. A survey on fall detection: Principles and approaches. *Neurocomputing* **2013**, *100*, 144–152.
- [3] Igual, R.; Medrano, C.; Plaza, I. Challenges, issues and trends in fall detection systems. *Biomed. Eng. Online* **2013**, *12*, 66.
- [4] Liu, H.; Xue, T.; Schultz, T. On a Real Real-Time Wearable Human Activity Recognition System. In Proceedings of the 16th International Joint Conference on Biomedical Engineering Systems and Technologies-WHC. INSTICC, SciTePress, Lisbon, Portugal, 16–18 February 2023; pp. 711–720.
- [5] Gia, T.N.; Sarker, V.K.; Tcareno, I.; Rahmani, A.M.; Westerlund, T.; Liljeberg, P.; Tenhunen, H. Energy efficient wearable sensor node for IoT-based fall detection systems. *Microprocess. Microsyst.* **2018**, *56*, 34–46.
- [6] Chatterjee, P.; Cymberknop, L.J.; Armentano, R.L. IoT-based decision support system for intelligent healthcare—applied to cardiovascular diseases. In Proceedings of the 2017 7th International Conference on Communication Systems and Network Technologies (CSNT), IEEE, Nagpur, India, 11–13 November 2017; pp. 362–366.
- [7] Wankhede, K.; Pednekar, S. Aid for ALS patient using ALS Specs and IOT. In Proceedings of the 2019 2nd International Conference on Intelligent Autonomous Systems (ICoIAS), IEEE, Singapore, 28 February–2 March 2019; pp. 146–149.
- [8] Pierleoni, P.; Belli, A.; Palma, L.; Pellegrini, M.; Pernini, L.; Valenti, S. A high reliability wearable device for elderly fall detection. *IEEE Sensors J.* **2015**, *15*, 4544–4553.
- [9] Tan, Y.K.; Merrett, G. *Wireless Sensor Networks: Application-Centric Design*; IntechOpen: London, UK, 2010.
- [10] Wang, Y.; Wu, K.; Ni, L.M. Wifall: Device-free fall detection by wireless networks. *IEEE Trans. Mob. Comput.* **2016**, *16*, 581–594.
- [11] LeMoyné, R.; Tomycz, N.; Mastroianni, T.; McCandless, C.; Cozza, M.; Peduto, D. Implementation of a smartphone wireless accelerometer platform for establishing deep brain stimulation treatment efficacy of essential tremor with machine learning. In Proceedings of the 2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), IEEE, Milan, Italy, 25–29 August 2015; pp. 6772–6775.
- [12] Bustamante, P.; Solas, G.; Grandez, K. Wireless device for people affected by neurodegenerative diseases. In Proceedings of the 5th International Conference on Soft Computing as Transdisciplinary Science and Technology, Cergy-Pontoise, France, 28–31 October 2008; pp. 106–111.

TÀI LIỆU THAM KHẢO

Tiếng Việt

1. ...

2. ...

3. ...

Tiếng Anh

4. ...

5. ...

6. ...

BẢN CAM ĐOAN

Tôi cam đoan đã thực hiện việc kiểm tra mức độ tương đồng nội dung luận văn qua phần mềm “**Kiểm Tra Tài Liệu**” một cách trung thực và đạt kết quả mức độ tương đồng không quá **11%** toàn bộ nội dung luận văn. Luận văn này sau khi đã kiểm tra qua phần mềm và bản cứng luận văn đã nộp để bảo vệ trước hội đồng. Nếu sai tôi xin chịu các hình thức kỷ luật theo quy định hiện hành của Học viện.

Hà Nội, ngày tháng năm 20##

Tác giả luận văn

Tên học viên

Kết quả kiểm tra trùng lặp #5370343

KiemTraTaiLieu



BÁO CÁO KIỂM TRA TRÙNG LẬP

Thông tin tài liệu

Tên tài liệu:	Xây dựng ứng dụng quản lý sinh viên tại Viện công nghệ thông tin và Truyền thông Lào
Tác giả:	Khamson Keovilay
Điểm trùng lặp:	11
Thời gian tải lên:	15:03 24/05/2023
Thời gian sinh báo cáo:	15:21 24/05/2023
Các trang kiểm tra:	71/71 trang




Kết quả kiểm tra trùng lặp




Có 11% nội dung trùng lặp



Có 89% nội dung không trùng lặp



Có 0% nội dung người dùng loại trừ



Có 0% nội dung hệ thống bỏ qua

Nguồn trùng lặp tiêu biểu

123docz.net tailieu.vn

HỌC VIÊN
(Ký và ghi rõ họ tên)

NGƯỜI HƯỚNG DẪN KHOA HỌC
(Ký và ghi rõ họ tên)

PHỤ LỤC